

TUGAS AKHIR - KT234801

**EVALUASI PERFORMA EKSTRAKSI FITUR *MEL* DAN
GAMMATONE FREQUENCY CEPSTRAL
COEFFICIENTS MENGGUNAKAN MODEL *DEEP*
LEARNING UNTUK KLASIFIKASI TUBERKULOSIS
BERDASARKAN SUARA BATUK**

NATHANIA CAHYA ROMADHONA

NRP 5049221016

Dosen Pembimbing

Dr. Dhany Arifianto, S.T., M.Eng.

NIP 197310071998021001

Dr. Alfian Nur Rosyid, dr., Sp.P(K), FAPSR, FCCP, FISR.

NIP 198203292015041001

Program Studi Teknologi Kedokteran

Fakultas Kedokteran dan Kesehatan

Institut Teknologi Sepuluh Nopember

Surabaya

2026

(Halaman ini sengaja dikosongkan)



TUGAS AKHIR - KT234801

**EVALUASI PERFORMA EKSTRAKSI FITUR *MEL* DAN
GAMMATONE *FREQUENCY* *CEPSTRAL*
COEFFICIENTS MENGGUNAKAN MODEL *DEEP*
LEARNING UNTUK KLASIFIKASI TUBERKULOSIS
BERDASARKAN SUARA BATUK**

NATHANIA CAHYA ROMADHONA

NRP 5049221016

Dosen Pembimbing

Dr. Dhany Arifianto, S.T., M.Eng.

NIP 197310071998021001

Dr. Alfian Nur Rosyid, dr., Sp.P(K), FAPSR, FCCP, FISR.

NIP 198203292015041001

Program Studi Teknologi Kedokteran

Fakultas Kedokteran dan Kesehatan

Institut Teknologi Sepuluh Nopember

Surabaya

2026

(Halaman ini sengaja dikosongkan)



FINAL PROJECT - KT234801

**PERFORMANCE EVALUATION OF MEL AND
GAMMATONE FREQUENCY CEPSTRAL COEFFICIENTS
FEATURE EXTRACTION USING DEEP LEARNING
MODEL FOR TUBERCULOSIS CLASSIFICATION BASED
ON COUGH SOUND**

NATHANIA CAHYA ROMADHONA

NRP 5049221016

Advisor

Dr. Dhany Arifianto, S.T., M.Eng.

NIP 197310071998021001

Dr. Alfian Nur Rosyid, dr., Sp.P(K), FAPSR, FCCP, FISR.

NIP 198203292015041001

Study Program Medical Technology

Faculty of Health and Medicine

Institut Teknologi Sepuluh Nopember

Surabaya

2026

(Halaman ini sengaja dikosongkan)

LEMBAR PENGESAHAN

EVALUASI PERFORMA EKSTRAKSI FITUR *MEL* DAN *GAMMATONE FREQUENCY CEPSTRAL COEFFICIENTS* MENGGUNAKAN MODEL *DEEP LEARNING* UNTUK KLASIFIKASI TUBERKULOSIS BERDASARKAN SUARA BATUK

TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Teknik pada
Program Studi S-1 Teknologi Kedokteran
Fakultas Kedokteran dan Kesehatan
Institut Teknologi Sepuluh Nopember

Oleh : **NATHANIA CAHYA ROMADHONA**

NRP. 5049221016

Disetujui oleh Tim Penguji Tugas Akhir :

- | | |
|--|---------------|
| 1. Dr. Dhany Arifianto, S.T., M.Eng | Pembimbing |
| 2. Dr. Alfian Nur Rosyid, dr., Sp.P(K), FAPSR, FCCP, FISR. | Ko-pembimbing |
| 3. Prof. Dr. Ir. Adhi Dharma Wibawa, S.T., M.T. | Penguji |
| 4. Yuri Pamungkas, S.Tr.T, M.T. | Penguji |

SURABAYA

Januari, 2026

(Halaman ini sengaja dikosongkan)

APPROVAL SHEET

PERFORMANCE EVALUATION OF MEL AND GAMMATONE FREQUENCY CEPSTRAL COEFFICIENTS FEATURE EXTRACTION USING DEEP LEARNING MODEL FOR TUBERCULOSIS CLASSIFICATION BASED ON COUGH SOUND

FINAL PROJECT

Submitted to fulfill one of the requirements
for obtaining a degree Bachelor of Engineering at
Undergraduate Study Program of Medical Technology
Faculty of Medicine and Health
Institut Teknologi Sepuluh Nopember

By : **NATHANIA CAHYA ROMADHONA**

NRP. 5049221016

Approved by Final Project Examiner Team:

-

- | | |
|---|--------------|
| 1. Dr. Dhany Arifianto, S.T., M.Eng. | Main Advisor |
| 2. Dr. dr. Alfian Nur Rosyid, Sp.P(K), FAPSR, FCCP, Co-Advisor
FISR. | |
| 3. Prof. Dr. Ir. Adhi Dharma Wibawa, S.T., M.T. | Examiner |
| 4. Yuri Pamungkas, S.Tr.T, M.T. | Examiner |

SURABAYA

January, 2026

(Halaman ini sengaja dikosongkan)

PERNYATAAN ORISINALITAS

Yang bertanda tangan di bawah ini:

Nama mahasiswa / NRP : Nathania Cahya Romadhona / 5049221016
Program studi : Teknologi Kedokteran
Dosen Pembimbing / NIP : Dr. Dhany Arifianto, S.T., M.Eng. / 197310071998021001

dengan ini menyatakan bahwa Tugas Akhir dengan judul “Evaluasi Performa Ekstraksi Fitur *Mel* Dan *Gammatone Frequency Cepstral Coefficients* Menggunakan Model *Deep Learning* Untuk Klasifikasi Tuberkulosis Berdasarkan Suara Batuk” adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Institut Teknologi Sepuluh Nopember.

Surabaya, 30 Januari 2026

Mengetahui
Dosen Pembimbing

Mahasiswa

Dr. Dhany Arifianto, S.T., M.Eng.
NIP. 197310071998021001

Nathania Cahya Romadhona
NRP. 5049221016

(Halaman ini sengaja dikosongkan)

STATEMENT OF ORIGINALITY

The undersigned below :

Name of Student/ NRP : Nathania Cahya Romadhona / 5049221016
Study Program : Medical Technology
Advisor/ NIP : Dr. Dhany Arifianto, S.T., M.Eng. / 197310071998021001

hereby declare that the Final Project with the title of “Performance Evaluation of Mel and Gammatone Frequency Cepstral Coefficients Feature Extracion Using Deep Learning Model For Tuberculosis Classification Based On Cough Sound” is the result of my own work, is original and written by following the rules of scientific writing.

If in the future there is discrepancy with this statement, then I am willing to accept sanctions in accordance with the provisions that apply at Institut Teknologi Sepuluh Nopember.

Surabaya, 30 January 2026

Acknowledge
Advisor

Student

Dr. Dhany Arifianto, S.T., M.Eng.
NIP. 197310071998021001

Nathania Cahya Romadhona
NRP. 5049221016

(Halaman ini sengaja dikosongkan)

ABSTRAK

EVALUASI PERFORMA EKSTRAKSI FITUR *MEL* DAN *GAMMATONE FREQUENCY CEPSTRAL COEFFICIENTS* MENGGUNAKAN MODEL *DEEP LEARNING* UNTUK KLASIFIKASI TUBERKULOSIS BERDASARKAN SUARA BATUK

Nama Mahasiswa / NRP : Nathania Cahya Romadona / 5049221016
Departemen : Teknologi Kedokteran FKK - ITS
Dosen Pembimbing : Dr. Dhany Arifianto, S.T., M.Eng.

Abstrak

Tuberkulosis (TB) masih menjadi salah satu tantangan kesehatan global utama, di mana metode diagnosis konvensional seringkali terbatas oleh biaya, waktu, dan aksesibilitas. Penelitian ini bertujuan mengevaluasi performa dan konfigurasi optimal fitur *Mel-Frequency Cepstral Coefficients* (MFCC) dan *Gammatone Frequency Cepstral Coefficients* (GFCC), serta membandingkan kinerja model *Convolutional Neural Network* (CNN) dan *Long Short-Term Memory* (LSTM) untuk klasifikasi biner batuk TB dan non-TB dengan mempertimbangkan variasi parameter ekstraksi fitur dan perbedaan perangkat perekaman. Metodologi mencakup pengumpulan dua jenis dataset, yaitu data sekunder CIRDZ sebagai data pelatihan dan pengujian awal, serta data primer yang direkam secara klinis di Poli DOTS TB RSUD menggunakan mikrofon INMP441S. Tahapan pemrosesan meliputi segmentasi batuk dengan *Voice Activity Detection*, validasi segmen menggunakan model YAMNet, kontrol kualitas akustik, ekstraksi fitur MFCC dan GFCC dengan variasi kanal *filterbank* dan jumlah koefisien DCT, augmentasi berbasis *SpecAugment*, pelatihan model CNN dan LSTM, serta evaluasi menggunakan akurasi, presisi, sensitivitas, *F1-score*, dan *Area Under Curve* (AUC). Hasil menunjukkan bahwa pada data sekunder, konfigurasi MFCC 32 kanal dengan 39 koefisien pada model LSTM dan beberapa kombinasi GFCC mampu mencapai akurasi hingga 96% dengan AUC mendekati 1, sedangkan pengujian pada data primer menghasilkan akurasi terbaik sekitar 75% pada model CNN dengan MFCC 40 kanal dan 13 koefisien, yang menegaskan adanya tantangan perbedaan domain dan kualitas perekaman. Secara keseluruhan, penelitian ini menyimpulkan bahwa pemilihan konfigurasi fitur dan arsitektur *deep learning* yang tepat berperan penting dalam meningkatkan performa dan potensi implementasi sistem pra-skrining TB berbasis suara batuk di lingkungan klinis nyata.

Kata kunci: Tuberkulosis, *Mel-Frequency Cepstral Coefficients* (MFCC), *Gammatone Frequency Cepstral Coefficients* (GFCC), Klasifikasi, *Deep learning*.

(Halaman ini sengaja dikosongkan)

ABSTRACT

PERFORMANCE EVALUATION OF MEL AND GAMMATONE FREQUENCY CEPSTRAL COEFFICIENTS FEATURE EXTRACION USING DEEP LEARNING MODEL FOR TUBERCULOSIS CLASSIFICATION BASED ON COUGH SOUND

Student Name / NRP : Nathania Cahya Romadhona / 5049221016
Department : Teknologi Kedokteran FKK - ITS
Advisor : Dr. Dhany Arifianto, S.T., M.Eng.

Abstract

Tuberculosis (TB) remains a major global health challenge, with conventional diagnostic methods often limited by cost, time, and accessibility. This study aims to evaluate the performance and optimal configuration of *Mel-Frequency Cepstral Coefficients* (MFCC) and *Gammatone Frequency Cepstral Coefficients* (GFCC) features, and compare the performance of *Convolutional Neural Network* (CNN) and *Long Short-Term Memory* (LSTM) models for *binary* classification of TB and non-TB coughs by considering variations in feature extraction parameters and differences in recording devices. The methodology includes collecting two types of datasets, namely secondary CIRDZ data as initial training and testing data, and primary data recorded clinically at the RSUA TB DOTS Clinic using an INMP441S microphone. The processing stages include cough segmentation with Voice Activity Detection, segment validation using the YAMNet model, acoustic quality control, MFCC and GFCC feature extraction with varying filterbank channels and the number of DCT coefficients, SpecAugment-based augmentation, CNN and LSTM model training, and evaluation using accuracy, precision, sensitivity, F1-score, and Area Under Curve (AUC). The results show that on secondary data, a 32-channel MFCC configuration with 39 coefficients in the LSTM model and several combinations of GFCCs are able to achieve an accuracy of up to 96% with an AUC close to 1, while testing on primary data produces the best accuracy of around 75% in the CNN model with 40-channel MFCC and 13 coefficients, which emphasizes the challenges of domain differences and recording quality. Overall, this study concludes that selecting the right feature configuration and *deep learning* architecture plays a crucial role in improving the performance and potential implementation of a cough-based TB pre-screening system in a real clinical setting.

Keywords: *Tuberculosis, Mel-Frequency Cepstral Coefficients (MFCC), Gammatone Frequency Cepstral Coefficients (GFCC), Classification, Deep learning.*

(Halaman ini sengaja dikosongkan)

KATA PENGANTAR

Puji syukur penulis panjatkan kepada Allah SWT atas rahmat, hidayah, dan karunia-Nya yang telah memberikan kemudahan dalam penyelesaian tugas akhir yang berjudul "Evaluasi Performa Fitur *Mel* Dan *Gammatone Frequency Cepstral Coefficients* Menggunakan Model *Deep learning* Untuk Klasifikasi Tuberkulosis Berdasarkan Suara Batuk" yang disusun sebagai salah satu syarat untuk memenuhi kelulusan mata kuliah tugas akhir di Program Studi Teknologi Kedokteran, Institut Teknologi Sepuluh Nopember Surabaya. Penulis dengan penuh rasa hormat mengucapkan terima kasih yang sebesar-besarnya kepada:

1. Ibu Dr. Shoffi Izza Sabilla, S.Kom selaku kepala Program Studi Teknologi Kedokteran Fakultas Kedokteran dan Kesehatan ITS.
2. Bapak Dr. Dhany Arifianto, S.T., M.Eng dan Bapak Dr. dr. Alfian Nur Rosyid, Sp.P(K), FAPSR, FCCP. selaku dosen pembimbing tugas akhir yang dengan penuh dedikasi telah memberikan bimbingan, arahan, dan dukungan, serta senantiasa meluangkan waktu untuk membimbing penulis dalam setiap tahapan penyusunan tugas akhir.
3. Bapak Prof. Dr. Ir. Adhi Dharma Wibawa, S.T., M.T. dan Bapak Yuri Pamungkas, S.Tr.T, M.T. selaku dosen penguji yang telah memberikan masukan, saran, wawasan, serta dukungan dalam penyempurnaan tugas akhir.
4. Bapak Prof. Dr. Ir. Adhi Dharma Wibawa, S.T., M.T. selaku dosen wali yang telah membimbing dan memberikan arahan kepada penulis sejak awal perkuliahan, sehingga penulis dapat menjalani proses akademik dengan baik.
5. Kedua orang tua, kakak dan keluarga yang selalu memberikan dukungan dan doa setiap saat dalam proses penulisan tugas akhir.
6. Teman-teman penulis yang selalu memberikan dukungan dan doa setiap saat dalam proses penulisan tugas akhir.
7. Teman-teman Teknologi Kedokteran angkatan 2022 Tourniquet yang menjadi rekan penulis dalam proses perkuliahan.
8. Semua pihak yang tidak dapat penulis sebutkan satu persatu yang secara langsung ataupun tidak langsung memberikan dukungan bagi penulis untuk menyelesaikan tugas akhir.

Surabaya, 29 Januari 2026

Penulis

(Halaman ini sengaja dikosongkan)

DAFTAR ISI

LEMBAR PENGESAHAN	i
APPROVAL SHEET	iii
PERNYATAAN ORISINALITAS	v
STATEMENT OF ORIGINALITY	vii
ABSTRAK	ix
ABSTRACT	ix
KATA PENGANTAR	xiii
DAFTAR ISI	xv
DAFTAR GAMBAR	xvii
DAFTAR TABEL	xix
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah	2
1.4 Tujuan	2
1.5 Manfaat	3
BAB 2 TINJAUAN PUSTAKA	11
2.1 Penelitian Terdahulu	11
2.2 Sinyal Akustik Suara Batuk	12
2.3 Segmentasi <i>Voice Activity Detection</i> (VAD)	13
2.4 Model <i>Pre-train Yet Another Mobile Network</i> (YAMNet)	13
2.5 Spektrogram Skala Perseptual Telinga Mel dan ERB	13
2.6 <i>Power Spectrum</i>	14
2.7 <i>Mel-Filterbank</i> dan <i>Gammatone-Filterbank</i>	15
2.8 Perkembangan Analisis Cepstrum	16
2.9 <i>Discrete Cosine Transform</i>	17
2.10 <i>Mel-Frequency Cepstral Coefficients</i> (MFCC)	18
2.11 <i>Gammatone Frequency Cepstral Coefficients</i> (GFCC)	19
2.12 Implementasi Model <i>Deep learning</i>	19
BAB 3 METODOLOGI	21
3.1 Diagram Alir Penelitian	21
3.2 Pengumpulan dan Karakteristik Data	22
3.2.1 Dataset Sekunder	22
3.2.2 Dataset Primer	23
3.3 Pra Pemrosesan Data	24
3.3.1 Segmentasi Audio dengan <i>Voice Activity Detection</i>	24
3.3.2 Validasi Suara Batuk dengan YAMnet	25
3.3.3 Kontrol Kualitas Akustik Pasca-Validasi	27
3.4 Analisis Karakteristik Spektral Suara Batuk	27
3.5 Ekstraksi Fitur MFCC dan GFCC	28
3.5.1 Tahap Pre-Emphasis	29
3.5.2 <i>Framing & Windowing</i>	29
3.5.3 <i>Discrete Fourier Transform</i>	30
3.5.4 Penerapan <i>Filterbank</i>	31
3.5.5 Kompresi Logaritmik (<i>Log-Filterbank Energy</i>)	33
3.5.6 <i>Discrete Cosine Transform</i> (DCT)	34
3.6 Augmentasi Data	35

3.7	Arsitektur dan Pelatihan Model <i>Deep Learning</i>	35
3.8	Evaluasi Matriks Klasifikasi.....	37
BAB 4	HASIL DAN PEMBAHASAN	39
4.1	Deskripsi Data Penelitian	39
4.1.1	Dataset Sekunder (CIRDZ)	39
4.1.2	Analisis Dataset Primer	40
4.1.3	Visualisasi Sinyal Data Sekunder dan Primer	41
4.2	Evaluasi Kinerja Model pada Dataset Sekunder (CIRDZ).....	42
4.3	Evaluasi Kinerja Model pada Dataset Primer Sebelum Augmentasi	47
4.4	Evaluasi Kinerja Model pada Dataset Primer Setelah Augmentasi	48
4.5	Analisi Komparasi Distribusi Fitur MFCC dan GFCC	50
BAB 5	KESIMPULAN DAN SARAN	53
5.1	Kesimpulan.....	53
5.2	Saran	53
	DAFTAR PUSTAKA	55
	LAMPIRAN.....	59
	Lampiran 1. Label Dataset Primer	59
	Lampiran 2. Label Dataset Sekunder (25 Data Pertama)	60
	Lampiran 3. Visualisasi Hasil Varian MFCC Sekunder	61
	Lampiran 4. Visualisasi Hasil Varian GFCC Sekunder.....	63
	BIODATA PENULIS	65

DAFTAR GAMBAR

Gambar 2.1 Fase Batuk (a) Perubahan Tekanan dan Aliran Udara.....	12
Gambar 2. 2 Proses Voice Activity Detection.....	13
Gambar 2. 3 (a) Perbandingan Perseptual Telinga (b) Spektogram Skala Mel, Bark dan ERB	14
Gambar 2. 4 (a) Mel Filterbank (Yaacob & Yusuf, 2013) (b) Gammatone Filterbank.....	16
Gambar 2. 5 Variasi Discrete Cosine Transform (Kulkarni et al., 2023).....	17
Gambar 2. 6 Visualisasi suara dalam (a) Waveform (b) Gammatone Spectrogram (c) Mel Spectrogram	18
Gambar 2. 7 Contoh Visualisasi Mel-Frequency Cepstral Coefficients	18
Gambar 2. 8 Speech Signal, Spectrogram, MFCC-Spectrogram and Gammatongram	19
Gambar 3. 1 Diagram Alir Penelitian.....	21
Gambar 3. 2 Distribusi Demografi Dataset Sekunder	22
Gambar 3. 3 Simulasi Pengambilan Data Primer di RSUD	23
Gambar 3. 4 Visualisasi Hasil Segmentasi Data Sekunder	25
Gambar 3. 5 Tahap Validasi Segmen Batuk dan Non Batuk	26
Gambar 3. 6 Distribusi Energi RMS Segmen Batuk Data Sekunder	27
Gambar 3. 7 Tahapan Ekstraksi Fitur MFCC dan GFCC.....	28
Gambar 3. 8 Visualisasi Audio Sebelum dan Sesudah Tahap Pre-emphasis	29
Gambar 3. 9 Tahap Framing dan Windowing	30
Gambar 3. 10 Hasil Tahap DFT dan Plot Spektogramnya	31
Gambar 3. 11 Respon Frekuensi Mel Filterbank 32 Kanal	32
Gambar 3. 12 Respon Frekuensi Mel Filterbank 32 Kanal	32
Gambar 3. 13 Respon Frekuensi ERB-Gammatone Filterbank 32 Kanal	33
Gambar 3. 14 Respon Frekuensi ERB-Gammatone Filterbank 40 Kanal	33
Gambar 3. 15 Log-Mel Spectrogram dan Log-Gammatone Spectrogram	34
Gambar 3. 16 MFCC dan GFCC dengan Koefisien 13	35
Gambar 3. 17 Arsitektur Model LSTM	36
Gambar 3. 18 Arsitektur Model CNN	37
Gambar 4. 1 Distribusi Durasi Batuk Pasien Dataset Cleaned Sekunder.....	39
Gambar 4. 2 Distribusi Durasi Batuk Pasien Dataset Cleaned Control Sekunder	39
Gambar 4. 3 Distribusi Data Sekunder Batuk Setelah dan Sebelum Augmentasi	40
Gambar 4. 4 Distribusi Demografi Dataset Primer	40
Gambar 4. 5 Distribusi Durasi Batuk Pasien Dataset Primer	40
Gambar 4. 6 Visualisasi Audio Sekunder dan Primer dalam Bentuk Raw dan Segmented.....	41
Gambar 4. 7 Visualisasi Hasil Ekstraksi Fitur Sekunder MFCC Kanal 32 Koefisien 39	43
Gambar 4. 8 (a) Confusion Matriks (b) Grafik Akurasi (c) Grafik Loss Hasil Ekstraksi Fitur Sekunder MFCC Kanal 32 Koefisien 39.....	43
Gambar 4. 9 Visualisasi Hasil Ekstraksi Fitur Sekunder GFCC Kanal 40 Koefisien 39	44
Gambar 4. 10 (a) Confusion Matriks (b) Grafik Akurasi (c) Grafik Loss Hasil Ekstraksi Fitur Sekunder GFCC Kanal 40 Koefisien 39	44
Gambar 4. 11 Visualisasi Hasil Ekstraksi Fitur Sekunder MFCC Kanal 32 Koefisien 39	45
Gambar 4. 12 (a) Confusion Matriks (b) Grafik Akurasi (c) Grafik Loss Hasil Ekstraksi Fitur Sekunder MFCC Kanal 32 Koefisien 39.....	45
Gambar 4. 13 Visualisasi Hasil Ekstraksi Fitur Sekunder GFCC Kanal 32 Koefisien 26	46

Gambar 4. 14 (a) Confusion Matriks (b) Grafik Akurasi (c) Grafik Loss Hasil Ekstraksi Fitur Sekunder GFCC Kanal 32 Koefisien 26	46
Gambar 4. 15 Visualisasi Hasil Ekstraksi Fitur MFCC 40 Kanal dan 13 Koefisien pada Data Primer Positif.....	49
Gambar 4. 16 Visualisasi Hasil Ekstraksi Fitur MFCC 40 Kanal dan 13 Koefisien pada Data Primer Negatif	49
Gambar 4. 17 Confusion Matriks untuk Data Primer (a) Model CNN (b) Model LSTM.....	50
Gambar 4. 18 Grafik Distribusi MFCC 32 Kanal dan 13 Koefisien	51
Gambar 4. 19 Grafik Distribusi MFCC 32 Kanal dan 39 Koefisien	51
Gambar 4. 20 Grafik Distribusi GFCC 32 Kanal dan 13 Koefisien.....	52
Gambar 4. 21 Grafik Distribusi GFCC 32 Kanal dan 26 Koefisien.....	52

DAFTAR TABEL

Tabel 2.1 Penelitian Terdahulu.....	11
Tabel 2. 2 Komparasi Sifat Single Filter Mel dan Gammatone-ERB	15
Tabel 3. 1 Spesifikasi Alat Perekaman Audio Sekunder.....	22
Tabel 3. 2 Variasi Jumlah Koefisien DCT	35
Tabel 4. 1 Hasil Performa Model CNN pada Data Sekunder.....	42
Tabel 4. 2 Hasil Performa Model LSTM Data Sekunder	45
Tabel 4. 3 Hasil Model CNN Data Primer Sebelum Augmentasi	47
Tabel 4. 4 Hasil Model LSTM Data Primer Sebelum Augmentasi.....	47
Tabel 4. 5 Hasil Model CNN Data Primer Setelah Augmentasi	48
Tabel 4. 6 Hasil Model LSTM Data Primer Setelah Augmentasi	48

(Halaman ini sengaja dikosongkan)

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Berdasarkan Laporan Tuberkulosis Global WHO 2024, penyakit tuberkulosis (TB) secara global menjadi tantangan kesehatan masyarakat yang signifikan. Pada tahun 2023, estimasi insidensi tuberkulosis global mencapai 10,8 juta kasus, dengan laju insidensi 134 kasus per 100.000 penduduk (WHO, 2024). Indonesia termasuk dalam lima negara yang menyumbang 56% dari total kasus insiden TB global, dengan kontribusi sebesar 10% yang menempatkan Indonesia pada peringkat kedua sebagai negara dengan beban kasus TB tertinggi di dunia setelah India (Rolo *et al.*, 2023). Tuberkulosis merupakan penyakit infeksi yang disebabkan oleh bakteri *Mycobacterium tuberculosis* yang menyebar melalui udara (CDC, 2023). Berdasarkan lokasi anatomisnya, tuberkulosis secara umum diklasifikasikan menjadi dua kategori yaitu tuberkulosis paru dan tuberkulosis ekstra paru. Berdasarkan data Kementerian Kesehatan tahun 2024, dari 856.420 kasus TB di Indonesia, 92% termasuk dalam kategori tuberkulosis paru.

Suara batuk yang dihasilkan oleh sistem pernapasan manusia merupakan sinyal akustik kompleks yang dapat diurai menjadi komponen harmonik dan inharmonik. Suara harmonik memiliki struktur frekuensi yang teratur, terdiri dari frekuensi fundamental (f_0) dan kelipatannya, sehingga menghasilkan suara yang terdengar jernih dan bernada (Abdul & Al-Talabani, 2022). Sebaliknya, komponen inharmonik bersifat bising (*noisy*), dengan energi spektral yang tersebar luas tanpa pola matematis yang jelas, seperti suara desisan (Kreiman, J., & Gerratt, 2012). Batuk yang dipicu oleh kondisi patologis seperti TB cenderung didominasi oleh komponen inharmonik. Hal ini disebabkan oleh turbulensi aliran udara yang meningkat akibat adanya peradangan, penyempitan saluran napas, atau keberadaan cairan seperti dahak (Pahar *et al.*, 2021). Meskipun telinga manusia dapat dengan mudah mendeteksi keberadaan batuk, kapasitasnya sangat terbatas untuk membedakan secara objektif pola-pola halus dan transisi antara komponen harmonik dan inharmonik yang dapat menjadi penanda penyakit (Ijaz *et al.*, 2022). Keterbatasan persepsi manusia inilah yang mendorong pemanfaatan analisis komputasional untuk klasifikasi yang lebih akurat.

Untuk merepresentasikan sinyal batuk secara numerik, metode ekstraksi fitur yang paling umum digunakan adalah *Mel-Frequency Cepstral Coefficients* (MFCC). Fitur ini bekerja dengan mengubah spektrum sinyal menggunakan Skala Mel, sebuah skala perseptual yang meniru sensitivitas pendengaran manusia terhadap nada (*pitch*) (Abdul & Al-Talabani, 2022). Meskipun sangat populer, efektivitas MFCC memiliki tantangan, terutama karena ia dirancang untuk sinyal ucapan yang cenderung harmonik. Penelitian ini mempelajari alternatif fitur yang secara teoretis lebih unggul, yaitu *Gammatone Frequency Cepstral Coefficients* (GFCC). Fitur GFCC menggunakan *Gammatone Filterbank* yang secara biologis lebih akurat dalam meniru respons koklea telinga manusia, terbukti lebih unggul terhadap *noise* dan lebih efektif untuk klasifikasi audio *non-speech* (Sharan, 2023).

Penelitian sebelumnya telah menunjukkan potensi besar dari pendekatan klasifikasi menggunakan fitur berbasis persepsi pendengaran. Studi oleh Suda (2023) berhasil mencapai AUC 88% menggunakan arsitektur 2D-CNN yang dimasukkan dengan *Mel-spectrogram*, sebuah fitur yang berkaitan erat dengan MFCC. Demikian pula, Balamurali *et al.* (2021) yang menggunakan model BiLSTM dengan fitur MFCC mendapatkan akurasi melebihi 91% dalam skenario biner (sehat vs. sakit). Namun, penelitian yang sama juga menyoroti kelemahan MFCC, di mana fitur dari berbagai penyakit cenderung tumpang tindih sehingga sulit dibedakan. Keterbatasan inilah yang menjadi justifikasi kuat untuk mengeksplorasi GFCC. Studi oleh Liu *et al.* (2013) menunjukkan bahwa GFCC mengungguli MFCC dalam pemodelan sinyal batuk.

Oleh karena itu, penelitian ini akan mengevaluasi secara langsung apakah keunggulan teoretis GFCC dapat menghasilkan performa klasifikasi TB yang lebih unggul saat diolah dengan model *deep learning*.

Berdasarkan penjelasan di atas, penelitian ini akan mengevaluasi performa ekstraksi fitur akustik MFCC dan GFCC dengan menggunakan arsitektur *deep learning* untuk klasifikasi TB dan non TB berdasarkan suara batuk. Terdapat 2 jenis data suara batuk TB dan non TB yang digunakan yaitu dataset sekunder dan dataset primer. Dataset sekunder didapatkan dari *Centre for Infectious Disease Research in Zambia* (CIDRZ). Sedangkan dataset primer dikumpulkan dari pasien di Poli DOTS TB RSKI Universitas Airlangga Surabaya. Bagian yang akan dipelajari adalah nilai hiperparameter pada MFCC dan GFCC secara masing-masing dalam menemukan representasi yang paling optimal untuk membedakan suara batuk TB dan Non TB. Fitur ini kemudian akan diumpungkan ke dalam dua jenis model *deep learning* yaitu *Convolutional Neural Network* (CNN) untuk menganalisis pola spektral-visual, dan *Long Short-Term Memory* (LSTM) untuk memodelkan dinamika sekuens temporalnya. Dengan membandingkan kinerja kedua model serta membandingkan dua metode ekstraksi fitur yaitu MFCC dan GFCC, penelitian ini bertujuan untuk mengetahui ekstraksi fitur mana yang unggul untuk klasifikasi TB berdasarkan suara batuk dengan arsitektur *deep learning*.

1.2 Rumusan Masalah

Rumusan masalah penelitian ini adalah analisis performa fitur MFCC dan GFCC untuk membedakan suara batuk TB dari batuk non-TB dengan memperhatikan nilai parameter ekstraksi fiturnya dan pengaruh alat perekaman terhadap kualitas audio. Kemudian bagaimana hasil evaluasi matriks arsitektur *deep learning* yang berbeda, yaitu *Convolutional Neural Network* (CNN) dan *Long Short-Term Memory* (LSTM) dalam mengolah fitur MFCC dan GFCC dalam membedakan suara batuk TB dari batuk non-TB.

1.3 Batasan Masalah

Dalam penelitian ini terdapat beberapa batasan masalah yang ditetapkan. Terdapat 2 jenis dataset yaitu sekunder dan primer. Dataset sekunder berasal dari *Centre for Infectious Disease Research in Zambia* (CIDRZ), kemudian data primer yang direkam langsung dari pasien di Poli Paru Rumah Sakit Universitas Airlangga (RSUA) Surabaya dan data naracoba normal dengan klasifikasi inklusi dan eksklusinya. Klasifikasi yang dilakukan bersifat biner, yaitu untuk membedakan antara kelas TB dan non-TB, dengan masing-masing fitur *Mel-Frequency Cepstral Coefficients* (MFCC) dan *Gammatone-Frequency Cepstral Coefficients* (GFCC) sebagai fitur akustik yang diekstraksi. Model *deep learning* yang digunakan akan terbatas pada perbandingan antara arsitektur *Convolutional Neural Network* (CNN) dan *Long Short-Term Memory* (LSTM).

1.4 Tujuan

Penelitian ini bertujuan untuk menganalisis performa fitur *Mel-Frequency Cepstral Coefficients* (MFCC) dan *Gammatone Frequency Cepstral Coefficients* (GFCC) dalam membedakan suara batuk TB dan non-TB, dengan meninjau pengaruh variasi parameter ekstraksi serta dampak penggunaan alat perekaman yang berbeda terhadap kualitas audio. Selain itu, penelitian ini bertujuan mengevaluasi dan membandingkan kinerja arsitektur *Deep learning*, khususnya *Convolutional Neural Network* (CNN) dan *Long Short-Term Memory* (LSTM), dalam mengolah fitur-fitur tersebut untuk menghasilkan sistem klasifikasi yang optimal.

1.5 Manfaat

Manfaat dari penelitian ini dapat dilihat dalam beberapa aspek berikut:

1. Bagi Ilmu Pengetahuan

Penelitian ini memberikan kontribusi terhadap pemahaman dan pengembangan teknik klasifikasi suara batuk untuk pra-skrining tuberkulosis (TB), yang memiliki tantangan terkait sinyal inharmonik dan bising. Dengan menggunakan fitur *Mel-Frequency Cepstral Coefficients* (MFCC) dan *Gamma-tone-Frequency Cepstral Coefficients* (GFCC), penelitian ini berpotensi meningkatkan efisiensi pra-skrining TB melalui analisis suara batuk.

2. Bagi Pelayanan Kesehatan

Hasil penelitian ini dapat menghasilkan sistem praskrining batuk TB yang efisien dan diharapkan dapat diimplementasikan di lingkungan dengan sumber daya terbatas untuk mempercepat proses penemuan kasus TB.

3. Bagi Masyarakat

Penelitian ini dapat memberikan solusi yang lebih nyaman dan non-invasif dalam praskrining TB, dengan memanfaatkan teknologi berbasis suara batuk yang dapat diakses lebih mudah, sehingga mendorong lebih banyak orang untuk melakukan praskrining secara rutin dan deteksi dini.

(Halaman ini sengaja dikosongkan)

BAB 2 TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Analisis komparatif terhadap penelitian terdahulu dilakukan dengan meninjau penggunaan fitur *Mel-Frequency Cepstral Coefficients* (MFCC) dan *Gamma-tone-Frequency Cepstral Coefficients* (GFCC) pada model *machine learning* atau *deep learning* yang digunakan. Analisis komparatif penelitian terdahulu ditunjukkan pada Tabel 2.1.


Tabel 2.1 Penelitian Terdahulu

Peneliti	Model	Fitur	Hasil	Kelemahan
(Sreeram <i>et al.</i> , 2020)	<i>Long Short-Term Memory</i> (LSTM)	<i>Mel-Frequency Cepstral Coefficients</i> (MFCC)	Model RNN-LSTM menunjukkan akurasi tinggi, dengan model untuk Bronchitis mencapai 100%, dan model untuk COPD danILD mencapai 97.39%.	<i>Overfitting</i> pada model Pneumonia, penggunaan dataset pribadi yang tidak dapat diakses publik, serta fokus terbatas hanya pada MFCC.
(Suda, 2023)	<i>Extremely Randomized Trees</i> (Extra-Trees), <i>Histogram-Based Gradient Boosting</i> (HGBost), dan 2D <i>Convolutional Neural Network</i> (2D-CNN)	<i>Mel-spectrograms</i> , <i>Mel-Frequency Cepstral Coefficients</i> (MFCCs), dan <i>Spectral Contrast</i>	2D-CNN menunjukkan kinerja terbaik dengan AUROC sebesar 88%	Ketergantungan pada aplikasi pra-klasifikasi eksternal untuk mendeteksi batuk, kompleksitas model <i>ensemble</i> yang memerlukan sumber daya komputasi tinggi, dan kurangnya perbandingan dengan model yang hanya menggunakan fitur MFCC untuk mengukur peningkatan performa.
(Balamurali <i>et al.</i> , 2021)	<i>Bidirectional Long-Short-Term Memory</i> (BiLSTM)	<i>Mel-Frequency Cepstral Coefficients</i> (MFCC)	Untuk klasifikasi biner, model menunjukkan akurasi yang sangat baik, mencapai 91.2% saat digabungkan per subjek. Namun, untuk klasifikasi multi-kelas, akurasi menurun menjadi 60%, meskipun model masih	Kesulitan dalam membedakan antara penyakit yang berbeda karena fitur MFCC yang tumpang tindih, serta bergantung pada segmentasi manual yang tidak praktis


			memiliki akurasi 84.4% dalam membedakan subjek sehat dari yang sakit.	
(Sharan, 2023)	<i>Multilayer Perceptron</i>	<i>Gammatone Cepstral Coefficients</i>	Berhasil mencapai akurasi rata-rata (76.31%) dalam mengklasifikasikan 7 jenis emosi menggunakan validasi silang <i>leave-one-subject-out</i> .	Keterbatasan penelitian ini terletak pada penggunaan dataset yang relatif terbatas (535 rekaman dari 10 subjek)
(Liu <i>et al.</i> , 2013)	<i>Support Vector Machine (SVM)</i>	<i>Mel-Frequency Cepstral Coefficients (MFCC), Gammatone Frequency Cepstral Coefficients (GFCC), Fitur Gabungan (MFCC dan GFCC)</i>	Penelitian ini menunjukkan bahwa GFCC secara signifikan lebih unggul dari MFCC untuk tugas klasifikasi batuk	Ukuran dataset yang digunakan sangat terbatas.

2.2 Sinyal Akustik Suara Batuk

Batuk merupakan refleks fisiologis yang berfungsi membersihkan saluran napas, menghasilkan suara melalui turbulensi udara, getaran jaringan, dan pergerakan cairan di sepanjang saluran napas (Ren *et al.*, 2022). Suara batuk umumnya terdiri atas tiga fase temporal, yaitu fase ledakan, menengah, dan menyuarakan. Fase batuk divisualisasikan pada Gambar 2.3 (a).



(a)



(b)


Gambar 2.1 Fase Batuk (a) Perubahan Tekanan dan Aliran Udara (Mann *et al.*, 2021)
(b) Data Suara Batuk (Serrurier *et al.*, 2022)

Deteksi pra-skrining tuberkulosis dapat dilakukan melalui analisis fitur akustik suara batuk, seperti *waveform* yang terbentuk dari amplitudo dan frekuensi, serta parameter turunannya

seperti *Mel-Frequency Cepstral Coefficients* (MFCC) dan *Gammatone-Frequency Cepstral Coefficients* (GFCC).

2.3 Segmentasi *Voice Activity Detection* (VAD)

Voice Activity Detection (VAD) merupakan teknik pemrosesan suara yang berfungsi untuk membedakan segmen yang mengandung ucapan manusia dari bagian sinyal yang berupa keheningan, derau, atau bunyi non-ucapan dalam suatu aliran audio (Jat *et al.*, 2019). VAD dapat direalisasikan sebagai sistem klasifikasi biner berbasis fitur spektral yang memproses sinyal dalam kerangka waktu pendek dan menghasilkan keputusan keberadaan ucapan pada tiap *frame* audio. VAD memetakan sinyal audio kontinu menjadi rangkaian *frame* berdurasi beberapa milidetik, kemudian mengekstraksi parameter seperti energi, rasio energi frekuensi rendah–tinggi, atau fitur spektral yang lebih kompleks, untuk menentukan apakah suatu *frame* mengandung ujaran.



Gambar 2. 2 Proses *Voice Activity Detection*

2.4 Model *Pre-train Yet Another Mobile Network* (YAMNet)

YAMNet merupakan model jaringan saraf konvolusional yang dirancang untuk klasifikasi kejadian audio, dilatih pada korpus AudioSet-YouTube yang mencakup 521 kelas peristiwa audio. Model ini mengadopsi arsitektur MobileNetV1 dengan konvolusi *depthwise-separable* untuk efisiensi komputasi, memproses sinyal audio mentah menjadi prediksi independen per *frame* waktu.


YAMNet memerlukan masukan sinyal audio yang diresample ke 16 kHz mono, diikuti perhitungan *Short-Time Fourier Transform* (STFT) dengan jendela 25 ms, *hop length* 10 ms, dan fungsi jendela Hann periodik. Spektrogram yang dihasilkan dipetakan ke 64 pita mel (rentang 125–7500 Hz), kemudian diterapkan *log stabilisasi log (mel-spectrum + 0.001)* untuk menghasilkan patch *Log-Mel Spectrogram* berukuran 64×96 (frekuensi $\times$ waktu) Patch ini dimasukkan ke MobileNetV1, yang menghasilkan aktivasi 3×2 dari 1024 *kernel* konvolusi teratas, dirata-rata menjadi *embedding* 1024-dimensi, lalu melalui lapisan logistik tunggal untuk skor 521 kelas. Model menghasilkan tiga keluaran utama: skor kelas (1×521), *embedding* 1024-dimensi sebagai ekstraktor fitur, serta *Log-Mel Spectrogram*.

2.5 Spektrogram Skala Perseptual Telinga Mel dan ERB

Logarithmic Spectrogram adalah spektrogram yang dimodifikasi untuk meniru cara kerja telinga manusia dengan diberikan fungsi logaritmik berskala (Suda, 2023). Proses ini dimulai dengan menghitung spektrum daya dari setiap *frame* sinyal audio, kemudian spektrum tersebut dilewatkan melalui sekumpulan filter yang disebut *Filterbank*. *Filterbank* ini tidak membagi frekuensi secara linear (dalam satuan Hertz), melainkan menggunakan skala perseptual telinga.

Skala perseptual untuk mengolah MFCC adalah Skala Mel dan GFCC adalah Skala ERB. Skala Mel yaitu sebuah skala perseptual yang lebih sensitif terhadap perubahan di frekuensi rendah dan kurang sensitif di frekuensi tinggi, sama seperti pendengaran manusia (Kopparapu & Laxminarayana, 2010) dengan kurva Skala Mel dapat dilihat pada Gambar 2.3 (a). Setelah energi dari setiap filter dihitung, nilai logaritmanya diambil untuk mengompresi rentang

dinamis dan lebih lanjut meniru persepsi kenyaringan suara manusia sebelum akhirnya divisualisasikan menjadi gambar spektrogram.



Gambar 2. 3 (a) Perbandingan Perseptual Telinga (Rohr, 2015) (b) Spektrogram Skala Mel, Bark dan ERB (dos Santos *et al.*, 2022)

Istilah "Mel" sendiri merupakan singkatan dari kata "melody" (melodi) dan diperkenalkan untuk menandakan skala nada atau *pitch* subjektif yang dinilai oleh pendengar setara dalam jarak satu sama lain (O'Shaughnessy, 2000). Dengan kata lain, kenaikan 100 Mel akan terdengar seperti kenaikan nada yang sama, terlepas dari apakah itu terjadi di frekuensi rendah atau tinggi. Skala ini secara matematis diformulasikan untuk mengubah satuan frekuensi fisik (Hertz) yang linear menjadi satuan perseptual (Mel) yang bersifat non-linear, di mana skala ini hampir linear di bawah 1 kHz dan menjadi logaritmik di atasnya.

Pengadopsian skala ini dalam komputasi fitur seperti MFCC atau *Log-Mel Spectrogram* terbukti efektif karena fitur yang dihasilkan menjadi lebih relevan secara biologis dan fokus pada aspek-aspek spektrum audio yang paling informatif bagi pendengaran manusia (Balamurali *et al.*, 2021).

Skala ERB (*Equivalent Rectangular Bandwidth*) digunakan dalam komputasi GFCC. Skala ERB juga bersifat non-linear, namun tidak didasarkan pada persepsi nada, melainkan pada lebar pita dari filter-filter dalam sistem pendengaran manusia yang diukur melalui eksperimen psikoakustik. Skala ini mendefinisikan bagaimana resolusi frekuensi dari telinga manusia berubah, di mana filter pendengaran lebih sempit pada frekuensi rendah dan lebih lebar pada frekuensi tinggi. Penggunaan skala ERB pada *Gammatone Filterbank* untuk meniru respons koklea secara lebih akurat, yang lebih unggul terhadap derau (*noise*) dan lebih efektif untuk sinyal *non-speech* (Liu *et al.*, 2013).

2.6 Power Spectrum

Tahapan *Power Spectrum* bertujuan untuk mendistribusikan daya dari komponen-komponen frekuensi yang menyusun sinyal audio. Dalam proses komputasi MFCC dan GFCC, setelah sinyal mentah dibagi menjadi beberapa segmen pendek yang disebut *frame*, kemudian dilakukan tahapan dengan metode *Discrete Fourier Transform* (DFT) untuk menghitung spektrum daya pada setiap *frame* tersebut. Proses ini secara efektif mengubah representasi sinyal dari domain waktu ke domain frekuensi, yang memungkinkan analisis harmonik dan pita samping (*sidebands*) dari sinyal. Hasil dari tahap ini adalah representasi kekuatan energi pada frekuensi yang berbeda untuk setiap *frame* sinyal yang dikalkulasikan dengan persamaan 2.1 :

$$X(k) = \sum_{n=0}^{N-1} x(n) e^{-\frac{2\pi j n k}{N}} \quad k = 1, 2, 3, \dots, N-1 \quad (2.1)$$

dimana $x(n)$ adalah sinyal diskrit dan N adalah panjang sinyal.

2.7 Mel-Filterbank dan Gammatone-Filterbank

Dalam ekstraksi fitur sinyal wicara, filterbank digunakan untuk memproyeksikan spektrum linier (Hz) ke skala perseptual yang lebih sesuai dengan cara telinga manusia menganalisis frekuensi. Mel-filterbank didasarkan pada skala Mel yang memodelkan persepsi pitch dan direalisasikan sebagai deret *single filter* band-pass berbentuk segitiga yang saling overlap di domain frekuensi. Setiap filter memiliki tiga titik utama (batas bawah, pusat, batas atas), dengan puncak bernilai *unity gain* di frekuensi pusat; bentuk ini dipilih untuk menyederhanakan pemodelan selubung spektral dan sudah lama menjadi standar dalam MFCC (Davis & Mermelstein, 1980; Koppurapu & Diwakar, 2014).


Gammatone-filterbank, sebaliknya, dirancang untuk memodelkan respons mekanik membran basilar di koklea. *Single filter* Gammatone didefinisikan di domain waktu sebagai hasil kali antara *Gamma envelope* dan sinusoida pada frekuensi pusat, dengan lebar pita ditentukan oleh *Equivalent Rectangular Bandwidth* (ERB). Pendekatan ini menghasilkan *roll-off* yang lebih curam dan bentuk passband yang halus tanpa ripple signifikan, sehingga memberikan aproksimasi yang lebih akurat terhadap selektivitas frekuensi sistem pendengaran manusia dibanding filter segitiga sederhana (Patterson et al., 1992; Moore & Glasberg, 1983; Jepsen et al., 2017). Komparasi sifat single filter Mel dan Gammatone-ERB dapat dilihat pada Tabel 2.2.

Tabel 2. 2 Komparasi Sifat Single Filter Mel dan Gammatone-ERB

Aspek	Single Mel filter	Single Gammatone-ERB filter
Domain	Domain frekuensi sebagai <i>band-pass</i> segitiga	Domain waktu sebagai respons impuls Gammatone
Bentuk respons	Magnitudo segitiga: naik linear dari 0 ke 1 di sekitar frekuensi pusat, turun linear kembali ke 0	Envelope Gamma berorde 3–4 yang dimodulasi sinusoida, bentuk lonceng asimetris
Parameter utama	Tiga frekuensi batas: <i>low</i> , <i>center</i> , <i>high</i> ; gain maksimum 1 di frekuensi center	Frekuensi pusat f_c dan <i>bandwidth</i> berbasis ERB yang bergantung pada f_c
Cutoff / roll-off	Tidak didefinisikan sebagai –3 dB; penurunan linear di magnitudo (bukan dB/oktav)	Roll-off spektral tajam di luar pita utama, mirip filter analog orde 4 dengan attenuasi cepat
Ripple passband/stopband	Hampir tidak ada <i>ripple</i> ; respons halus dan monoton untuk mengakumulasi energi di sekitar frekuensi pusat	<i>Passband</i> mulus tanpa <i>ripple</i> signifikan; bentuk diturunkan dari model psikoakustik koklea
Skala frekuensi	Pusat filter disusun menurut skala Mel (hampir linier di <1 kHz, logaritmik di frekuensi tinggi)	Pusat dan lebar pita disusun menurut skala ERB (<i>band</i> sempit di rendah, melebar di frekuensi tinggi)

Frequency band merujuk pada satu pita frekuensi tertentu yang diloloskan oleh satu filter *band-pass*, sedangkan filter bank adalah kumpulan banyak filter *band-pass* yang disusun

paralel untuk memecah spektrum menjadi beberapa *frequency band* yang saling berurutan. Mel filterbank terdiri dari sejumlah filter segitiga pada skala Mel yang masing-masing mewakili satu *frequency band*, sehingga keseluruhan bank tersebut meniru sensitivitas non-linear telinga manusia terhadap frekuensi, sebagaimana ditunjukkan pada Gambar 2.4(a).



Gambar 2. 4 (a) *Mel Filterbank* (Yaacob & Yusuf, 2013) (b) *Gammatone Filterbank* (Frame Theory for Signal Processing in Psychoacoustics, 2016)

Gammatone filterbank, sebaliknya, dibangun dari filter *Gammatone* yang secara matematis memodelkan respons impuls membran basilar di koklea (rumah siput). Pusat frekuensi dan lebar setiap *frequency band* diatur menggunakan skala ERB sehingga lebih sesuai dengan lebar pita filter pendengaran manusia yang diukur secara psikoakustik. Ilustrasi bentuk dan sebaran *frequency band* ini ditampilkan pada Gambar 2.4(b). Dengan menerapkan kedua jenis filterbank tersebut pada *power spectrum*, skala frekuensi linear diubah menjadi representasi perseptual, yaitu skala Mel untuk komputasi MFCC dan skala ERB untuk komputasi GFCC, yang kemudian dapat dioptimalkan melalui variasi jumlah filter dan rentang frekuensi.

2.8 Perkembangan Analisis Cepstrum

Analisis Cepstrum adalah sebuah teknik pengolahan sinyal yang merupakan anagram dari kata Spectrum (spektrum), diperkenalkan untuk menganalisis data deret waktu yang mengandung gema atau sinyal periodik (Bogert *et al.*, 1963). Teknik ini pada dasarnya adalah hasil dari penerapan transformasi Fourier pada logaritma dari spektrum daya sebuah sinyal (Abdul & Al-Talabani, 2022). Secara konseptual, jika sebuah sinyal di domain waktu mengandung gema, maka spektrum dayanya akan memiliki sebuah riak (*ripple*) periodik. Analisis spektrum dari log spektrum daya disebut sebagai analisis *quefrency* dapat mendeteksi "frekuensi" dari riak, di mana "frekuensi" tersebut sebenarnya merepresentasikan waktu tunda dari gema. Secara matematis, jika $y(t)$ adalah sinyal asli dan $z(t) = y(t) + \alpha \cdot y(t - \tau)$ adalah sinyal dengan gema beramplitudo α dan waktu tunda τ , maka logaritma dari spektrum dayanya adalah sekitar $\log \Phi(f) + 2\alpha \cos(2\pi f\tau)$. *Cepstrum* dihitung dengan melakukan transformasi Fourier pada untuk mendeteksi puncak pada *quefrency* τ , yang memungkinkan identifikasi gema yang mungkin tersembunyi.

Dalam konteks ekstraksi fitur MFCC dan GFCC analisis *cepstrum* memegang peranan krusial pada tahap akhir untuk menghasilkan representasi fitur yang ringkas dan kuat. Setelah spektrum daya sinyal diolah menggunakan *Mel Filterbank* dan *Gammatone Filterbank* kemudian nilai logaritmanya diambil, langkah terakhir adalah menerapkan Discrete Cosine Transform (DCT). DCT dalam hal ini berfungsi sebagai implementasi praktis dari analisis *cepstrum* yang mengubah data dari domain frekuensi-logaritmik kembali ke domain yang mirip dengan waktu, yang disebut domain *quefrency*. Fungsi utama DCT di sini adalah untuk melakukan de-korelasi, yaitu memisahkan hubungan antar energi dari filter-filter Mel yang berdekatan dan memadatkan informasi spektral yang paling penting ke dalam beberapa

koefisien pertama. Koefisien-koefisien hasil transformasi inilah yang disebut MFCC, di mana istilah *Cepstral* pada MFCC merujuk pada operasi *cepstrum* ini (Abdul & Al-Talabani, 2022). Secara matematis, DCT dihitung menggunakan persamaan:


$$X(k) = \sum_{n=0}^{N-1} Xn * \cos(2\pi jnk/N) \quad (2.2)$$

di mana Xn adalah sinyal input (dalam hal ini, energi logaritmik dari *Mel Filterbank*) dan $X(k)$ adalah koefisien DCT yang dihasilkan, yang kemudian menjadi koefisien MFCC.


Pada GFCC, setelah energi dari setiap sub-band *Gammatone Filterbank* dihitung, fungsi logaritma dan *Discrete Cosine Transform* (DCT) diterapkan untuk mendekorelasi output filter yang telah dikompresi secara logaritmik. Tujuannya sama, yaitu untuk menghasilkan representasi fitur yang lebih ringkas dan representatif. Koefisien akhir yang dihasilkan dari proses ini disebut *Gammatone Frequency Cepstral Coefficients* (GFCC).

2.9 Discrete Cosine Transform

Discrete Cosine Transform (DCT) adalah tahapan akhir dalam kerangka kerja MFCC dan GFCC yang berfungsi untuk menghasilkan fitur akhir. DCT adalah proses matematis yang merepresentasikan sekumpulan titik data sebagai hasil penjumlahan fungsi kosinus dengan frekuensi yang berbeda-beda. Dalam komputasi MFCC, DCT diterapkan pada nilai logaritma dari energi yang keluar dari setiap filter di *Mel Filterbank*. Demikian pula, dalam komputasi GFCC, DCT diterapkan pada output non-linear dari energi yang keluar dari setiap filter di *Gammatone Filterbank*. Tujuan utama dari penerapan DCT pada kedua metode ini adalah untuk mendekorelasi output dari *filterbank* (memisahkan hubungan antar koefisien) dan memilih koefisien yang paling signifikan, sehingga menghasilkan representasi fitur yang lebih ringkas dan efisien. Koefisien-koefisien yang dihasilkan dari proses DCT inilah yang disebut sebagai *Mel Frequency Cepstral Coefficients* (MFCC) atau *Gammatone Frequency Cepstral Coefficients* (GFCC).




Gambar 2. 5 Variasi *Discrete Cosine Transform* (Kulkarni et al., 2023)



Gambar 2. 6 Visualisasi suara dalam (a) *Waveform* (b) Gammatone Spectrogram (c) Mel Spectrogram (Sharan, 2023)

2.10 Mel-Frequency Cepstral Coefficients (MFCC)


Mel-Frequency Cepstral Coefficients (MFCC) adalah representasi fitur yang diekstraksi dari sinyal audio dan sangat populer digunakan karena kemampuannya meniru sistem pendengaran manusia . Proses komputasinya dimulai dengan membagi sinyal menjadi *frame-frame* pendek yang tumpang tindih (*framing* dan *windowing*), lalu setiap *frame* diubah ke domain frekuensi menggunakan *Fast Fourier Transform* (FFT) untuk mendapatkan spektrum dayanya. Spektrum daya ini kemudian dilewatkan melalui *Mel Filterbank*, yaitu sekumpulan filter yang spasinya diatur berdasarkan Skala Mel, sebuah skala perseptual non-linear. Hubungan antara frekuensi linear f (dalam Hz) dan Skala Mel m didefinisikan oleh rumus (1). Setelah energi dari setiap filter dihitung dan nilai logaritmanya diambil, langkah terakhir adalah menerapkan *Discrete Cosine Transform* (DCT) untuk melakukan de-korelasi dan memadatkan informasi spektral yang paling signifikan ke dalam beberapa koefisien pertama. Contoh visualisasi *Mel-Frequency Cepstral Coefficients* terdapat pada Gambar 2.7.



Gambar 2. 7 Contoh Visualisasi *Mel-Frequency Cepstral Coefficients*

Keunggulan utama MFCC pada sinyal harmonik terletak pada kemampuannya yang terbukti efektif dalam mengekstraksi informasi mengenai komponen harmonik dan *sidebands* dari versi spektrum sebuah sinyal. Kemampuan ini berasal dari desain MFCC yang dapat menangkap fitur traktus vokal, di mana ia merepresentasikan bentuk keseluruhan dari selubung

spektral (*spectral envelope*) sehingga struktur harmonik yang teratur dapat dimodelkan secara efisien. Plot MFCC akan menampilkan pola-pola warna yang teratur dan stabil di sepanjang sumbu waktu, terutama pada koefisien-koefisien orde rendah, yang mencerminkan selubung spektral yang konsisten dan bersih.



Gambar 2. 8 *Speech Signal, Spectrogram, MFCC-Spectrogram and Gammatogram*
 (a) *Clean Speech* (b) *Noisy Speech* (Fedila & Amrouche, 2018)

Kelemahan utama dari MFCC yang menjadi tantangan dalam pemrosesan sinyal inharmonik adalah sensitivitasnya terhadap derau (*noise*) dan desainnya yang secara inheren dioptimalkan untuk sinyal ucapan (Abdul & Al-Talabani, 2022). Berbagai penelitian melaporkan bahwa performa MFCC dapat menurun secara signifikan di lingkungan yang bising. Tantangan ini menjadi lebih nyata saat memproses sinyal inharmonik seperti batuk patologis karena komputasi MFCC tradisional yang dirancang untuk menangkap fitur traktus vokal manusia belum tentu optimal untuk sinyal dengan struktur yang berbeda. Sehingga, pemilihan jumlah koefisien juga sangat krusial; penggunaan jumlah koefisien yang tidak tepat dapat menghasilkan representasi fitur dengan varian yang tinggi dan kurang kuat. Oleh karena itu, keberhasilan penerapan MFCC pada sinyal inharmonik sangat bergantung pada modifikasi atau optimalisasi parameternya agar mampu merepresentasikan karakteristik unik dari sinyal tersebut secara andal.

2.11 Gammatone Frequency Cepstral Coefficients (GFCC)

Gammatone Frequency Cepstral Coefficients (GFCC) adalah fitur akustik yang dirancang untuk meningkatkan ketahanan terhadap derau dengan meniru sistem pendengaran manusia secara lebih akurat. Proses komputasinya sangat mirip dengan MFCC, namun perbedaan fundamentalnya terletak pada penggantian *Mel Filterbank* dengan *Gammatone Filterbank*. Filter Gammatone ini secara teoretis lebih mendekati respons koklea telinga manusia, sehingga memberikan resolusi yang lebih baik pada frekuensi rendah (Zhao & Wang, 2013).

Keunggulan utama GFCC adalah performanya yang secara signifikan lebih superior dibandingkan MFCC dalam kondisi lingkungan yang bising. Fitur ini terbukti lebih tangguh dalam menekan berbagai jenis derau seperti *white noise*, *babble noise*, dan *street noise*, serta lebih andal untuk aplikasi pada jaringan VoIP yang sering mengalami degradasi sinyal seperti *packet loss* (Ayoub *et al.*, 2016).

2.12 Implementasi Model Deep learning

Penerapan *Artificial Intelligence* (AI), khususnya *deep learning* (DL), telah menunjukkan tren yang sangat menjanjikan dalam diagnosis penyakit pernapasan melalui sinyal akustik seperti suara batuk (Luies & Preez, 2020). Berbeda dengan metode *machine learning* (ML) konvensional yang performanya sangat bergantung pada fitur rekayasa tangan (*hand-crafted*

features), arsitektur DL memiliki keunggulan dalam kemampuannya untuk mempelajari representasi fitur tingkat tinggi secara otomatis dan hierarkis langsung dari data. Kemampuan ini sangat penting karena suara batuk patologis mengandung banyak sekali informasi laten dan nuansa halus yang sulit untuk dideskripsikan secara manual namun dapat ditangkap oleh model DL. Sejumlah penelitian telah membuktikan bahwa pendekatan berbasis DL dapat menjadi alat diagnostik yang kuat dengan mencapai akurasi tinggi dalam membedakan berbagai kondisi pernapasan (Bhavani *et al.*, 2022).

Convolutional Neural Network (CNN) merupakan salah satu arsitektur *deep learning* yang sangat efektif untuk tugas klasifikasi, terutama ketika data dapat direpresentasikan dalam format grid 2D seperti gambar. Dalam konteks analisis suara, konsep ini diterapkan dengan memperlakukan matriks fitur 2D (baik MFCC maupun GFCC) sebagai sebuah “gambar” spektral. Arsitektur CNN bekerja dengan lapisan-lapisan konvolusi yang menggunakan serangkaian filter atau kernel untuk mengekstrak pola-pola lokal dari representasi tersebut. Pola-pola ini dapat berupa tekstur atau bentuk spektral unik yang berpotensi menjadi penanda kondisi patologis. Setelah melalui beberapa lapisan konvolusi dan *pooling* untuk mereduksi dimensi serta menangkap fitur yang lebih abstrak, jaringan akan memetakan fitur-fitur yang telah dipelajari ke kelas akhir, sehingga mampu mempelajari dan membedakan ciri visual dari suara batuk tuberkulosis.


Untuk menangkap informasi dinamis atau urutan temporal dari sinyal suara, arsitektur *Long Short-Term Memory* (LSTM), yang merupakan varian dari *Recurrent Neural Network* (RNN), menjadi sangat relevan. LSTM dirancang secara khusus untuk memodelkan dependensi jangka panjang dalam data sekuensial, seperti urutan vektor fitur yang diekstraksi dari setiap *frame* suara batuk. Konsep dasarnya terletak pada mekanisme “gerbang” (*gates*) internal yang secara cerdas mengatur aliran informasi, memungkinkan sel memori untuk menyimpan informasi penting dari awal sekuens dan menggunakannya untuk menginterpretasikan bagian akhir. Dengan kemampuan ini, LSTM dapat memahami “alur cerita” atau evolusi temporal dari sebuah peristiwa batuk, yang menjadikannya sangat kuat dalam membedakan antara batuk sehat dan batuk dari berbagai kondisi patologis pernapasan.

BAB 3 METODOLOGI

Proses identifikasi evaluasi performa ekstraksi fitur akustik *Mel Frequency Cepstral Coefficients* (MFCC) dan *Gammamtone Frequency Cepstral Coefficients* (GFCC) disajikan dalam penjelasan di bawah ini.

3.1 Diagram Alir Penelitian

Tuberkulosis (TB) dari sinyal akustik batuk menggunakan pendekatan *deep learning*. Alur penelitian dibagi menjadi lima tahapan utama: karakteristik data, pra-pemrosesan data, ekstraksi fitur, implementasi model *deep learning*, dan evaluasi matriks. Setiap tahapan dilakukan secara berurutan untuk memastikan integritas data dan validitas hasil akhir dengan diagram alir pada Gambar 3.1.




Gambar 3. 1 Diagram Alir Penelitian

3.2 Pengumpulan dan Karakteristik Data

Dalam penelitian ini terdapat 2 jenis dataset yaitu dataset sekunder dan dataset primer. Dataset sekunder digunakan sebagai data training untuk membuat model klasifikasi, sedangkan dataset primer digunakan sebagai data pengujian pada kondisi aktual.

3.2.1 Dataset Sekunder

Dataset sekunder merupakan data yang didapatkan secara tidak langsung. Penelitian ini menggunakan dataset sekunder yang bersumber dari Google Health AI yang dikumpulkan oleh *Center for Infectious Disease Research in Zambia* (CIDRZ). Pengumpulan data ini dilakukan di tiga fasilitas kesehatan di Lusaka, Zambia, yaitu Chainta-South, Chawama, dan Kanyama.



Gambar 3. 2 Distribusi Demografi Dataset Sekunder

Berdasarkan karakteristik demografinya yang tervisualisasikan pada Gambar 3.2, dataset ini mencakup dari 1.828 data. Data sebaran menunjukkan adanya ketimpangan yang signifikan antara kelas non-TB dan TB, di mana terdapat 1.623 non-TB dibandingkan dengan hanya 205 yang terkonfirmasi TB. Dari sisi usia, mayoritas partisipan merupakan kelompok usia produktif, dengan jumlah terbanyak pada kategori 25-35 tahun (551 orang) dan 35-45 tahun (442 orang). Distribusi jenis kelamin terdiri dari 975 perempuan dan 853 laki-laki.

Akuisisi data dilaksanakan menggunakan empat perangkat sekaligus, yakni perekam profesional Zoom H2N disandingkan dengan tiga ponsel pintar: Samsung Galaxy A22 (*high-tier*), Samsung Galaxy A12 (*mid-tier*), dan Google Pixel 3a (*low-tier*) dengan spesifikasi singkat alat perekaman pada Tabel 3.1. Setiap partisipan diminta untuk melepas masker dan melakukan empat kejadian batuk, yang terdiri dari tiga batuk tunggal dan satu rangkaian batuk berurutan, dengan jeda waktu 10-15 detik antar kejadian. durasi setiap suara batuk bersifat variatif karena tidak adanya batasan waktu yang saat batuk direkam secara natural.

Tabel 3. 1 Spesifikasi Alat Perekaman Audio Sekunder

Perangkat	Tipe Mikrofon	Karakteristik Audio	Rentang Frekuensi Respon
Zoom H2N	5-built-in Condenser Mics (Mid-Side & X/Y Stereo)	Menangkap audio murni tanpa <i>processing</i> agresif. <i>Dynamic range</i> luas.	20 Hz - 20 kHz
Samsung Galaxy A22	MEMS (Micro-Electro-	Cenderung memiliki <i>noise suppression</i> bawaan yang mungkin memotong frekuensi rendah/tinggi ekstrem.	100 Hz - 10 kHz

Perangkat	Tipe Mikrofon	Karakteristik Audio	Rentang Frekuensi Respon
Samsung Galaxy A12	Mechanical Systems)	Kualitas ADC (<i>Analog to Digital Converter</i>) standar, <i>noise floor</i> mungkin lebih tinggi dari A22.	100 Hz - 10 kHz
	MEMS (Micro-Electro-Mechanical Systems)		
Google Pixel 3a	MEMS (Digital MEMS)	Mengandalkan <i>software</i> Google untuk kejernihan suara. Hardware mic standar.	100 Hz - 10 kHz

3.2.2 Dataset Primer

Pengumpulan karakteristik data primer dilakukan melalui perekaman suara batuk secara langsung yang melibatkan dua kelompok subjek, yaitu pasien terkonfirmasi Tuberkulosis (TBC) dan partisipan sehat (non-TBC). Proses pengambilan data pasien TBC dipusatkan di Poli DOTS TB Rumah Sakit Universitas Airlangga (RSUA) Surabaya, sedangkan perekaman data kontrol sehat dilaksanakan di lingkungan Kampus Institut Teknologi Sepuluh Nopember (ITS). Seluruh rangkaian akuisisi data ini dilakukan di bawah supervisi ketat dokter spesialis paru dan telah mematuhi protokol etik penelitian, yang dibuktikan dengan adanya surat izin kelayakan etik dari komite terkait serta lembar persetujuan (*informed consent*) yang telah ditandatangani oleh setiap partisipan.



Gambar 3. 3 Simulasi Pengambilan Data Primer di RSUA

Perekaman suara primer memanfaatkan perangkat keras khusus berbasis mikrofon MEMS INMP441S dengan visualisasi seperti pada Gambar 3.3. Pengambilan suara dilakukan dengan menjaga jarak sejauh 30-60 cm antara mikrofon dan naracoba untuk menstandarisasi intensitas audio. Setiap partisipan diinstruksikan untuk melakukan dua metode batuk induksi, yaitu batuk spontan (*coughing*) dan teknik hembusan napas paksa (*huffing*). Guna menjamin validitas kualitas audio dari modul INMP441S, telah dilakukan proses kalibrasi sinyal dengan membandingkannya terhadap alat perekam Zoom H4N sebagai acuan standar. Dalam penelitian ini, partisipan dibagi menjadi dua kelompok, yaitu partisipan normal atau sehat dan partisipan pasien tuberkulosis. Masing-masing kelompok harus memenuhi kriteria inklusi dan eksklusi sebagai berikut. Dalam penelitian ini, partisipan penelitian dibagi menjadi dua kelompok, yaitu partisipan normal/sehat dan partisipan pasien tuberkulosis, dengan kriteria sebagai berikut.

Kriteria inklusi partisipan normal atau sehat :

- Berusia lebih atau sama dengan 30 tahun.
- Menandatangani lembar persetujuan (*Informed Consent*)

- Sehat untuk melakukan perekaman suara batuk dan telah melakukan *Medical Check Up* dalam 1 tahun terakhir dengan keterangan sehat pada pemeriksaan X-Ray Thoraks.

Kriteria inklusi partisipan pasien tuberkulosis :

- Berusia lebih atau sama dengan 30 tahun.
- Menandatangani lembar persetujuan (*Informed Consent*)

Kriteria eksklusi partisipan normal atau sehat :

- Perokok

Kriteria eksklusi partisipan pasien tuberkulosis :

- Pasien Tuberkulosis MDR TB atau XDR TB
- Komorbid (HIV+)

3.3 Pra Pemrosesan Data

Tahapan pra-pemrosesan bertujuan untuk mengonversi data mentah (*raw data*) menjadi segmen-segmen sinyal yang bersih dan relevan untuk dijadikan sebagai input ekstraksi fitur. Proses ini dilakukan secara komputasi menggunakan *python*.

3.3.1 Segmentasi Audio dengan Voice Activity Detection

Setiap berkas audio dimuat ke dalam sistem dengan frekuensi cuplikan (*sampling rate*) fs sebesar 22.050 Hz pada kanal mono. Proses ini bertujuan untuk memisahkan sinyal suara yang mengandung informasi (batuk) dari bagian yang tidak relevan. Pemilihan nilai 22.050 Hz ini didasarkan pada Teorema Nyquist yang menyatakan bahwa frekuensi sampling harus setidaknya dua kali lipat dari frekuensi maksimum sinyal yang ingin dianalisis. Komponen spektral utama suara manusia berada di bawah 11 kHz, sehingga nilai fs sudah mencukupi untuk merekonstruksi sinyal sekaligus menjaga efisiensi komputasi.

Sebelum sinyal dipotong-potong, dilakukan tahap Pre-emphasis menggunakan filter IIR (*Infinite Impulse Response*). Pre-emphasis adalah *high-pass filtering* yang bertujuan untuk meratakan spektrum sinyal. Secara alami, energi suara manusia cenderung menurun pada frekuensi tinggi (*spectral tilt*). Dengan menerapkan filter ini, amplitudo pada frekuensi tinggi diperkuat agar informasi detail pada spektrum tersebut tidak hilang saat proses ekstraksi fitur. Digunakan filter IIR dengan koefisien pembilang $b = [0.9770, -0.9770]$ dan penyebut $a = [1.000, -0.9540]$. Proses *filtering* ini dapat direpresentasikan dalam domain-Z sebagai fungsi alih $H(z)$ dengan persamaan berikut:

$$H(z) = \frac{Y(z)}{X(z)} = \frac{b_0 + b_1 z^{-1}}{a_0 + a_1 z^{-1}} \quad (3.1)$$

Keterangan :

- $Y(z)$ adalah sinyal keluaran (terfilter).
- $X(z)$ adalah sinyal masukan.
- Koefisien filter : $b_0 = 0.9770, b_1 = -0.9770, a_0 = 1.000, a_1 = -0.9540$

Untuk memisahkan segmen batuk dari keheningan (*silence*) atau derau (*background noise*), diterapkan algoritma *Voice Activity Detection* (VAD). Algoritma ini memproses sinyal menggunakan teknik *Short-Time Fourier Transform* (STFT) dengan parameter *framing* sebagai berikut : *window length* (w_{len}) senilai 25 ms, *hop length* (h_{len}) senilai 10 ms dan N_{FFT} senilai 512. Tujuan penerapan *windowing* ini adalah untuk memperhalus diskontinuitas pada tepi-tepi bingkai, sehingga meminimalkan terjadinya kebocoran spektral (*spectral leakage*) ketika sinyal dikonversi ke domain frekuensi.

Keputusan VAD didasarkan pada dua parameter utama, yaitu Spectral Flux dan Energi Sinyal. Spectral Flux ($\mathcal{F}$) mengukur perubahan besaran spektrum antar *frame* berurutan untuk mendeteksi permulaan (*onset*) sinyal. Flux dihitung menggunakan jarak Euclidean pada spektrum yang ternormalisasi dengan persamaan sebagai berikut :

$$\mathcal{F}_n = \sum_{k=0}^{N/2} (|X_n[k]| - |X_{n-1}[k]|)^2 \quad (3.2)$$


Keterangan :

- $\mathcal{F}_n$ adalah nilai *Spectral Flux* pada *frame* ke- n .
- $|X_n[k]|$ adalah magnitudo spektrum DFT pada frekuensi k untuk *frame* n .
- Ambang batas (*threshold*) flux ditetapkan sebesar 0.5.

Sistem menggunakan ambang batas adaptif untuk mendeteksi keberadaan sinyal berdasarkan rasio energi atau *Signal-to-Noise Ratio* (SNR). Ambang batas deteksi VAD (*vadThres*) ditetapkan sebesar 0.4 dengan *energy floor* sebesar e^{-50} untuk menghindari kesalahan kalkulasi logaritmik pada kondisi hening total.

$$S_i = \{x[t], t_{start} \leq t \leq t_{end}, VAD[n] = 1\}$$

Segmen dianggap aktif ($VAD[n] = 1$) jika parameter spektral dan energi melampaui ambang batas yang ditentukan. Algoritma melakukan ekstraksi segmen waktu S_i di mana status VAD bernilai aktif (1) secara kontinu. Contoh visualisasi hasil segmentasi seperti Gambar 3.4.




Gambar 3. 4 Visualisasi Hasil Segmentasi Data Sekunder

3.3.2 Validasi Suara Batuk dengan YAMnet

Setelah tahap segmentasi dengan VAD, masih dimungkinkan terdapat segmen audio yang berisi suara non-batuk (seperti bicara) yang lolos. Oleh karena itu, diterapkan tahapan validasi suara segmentasi berbasis *deep learning* menggunakan model YAMNet (*Yet Another Mobile*

Network) untuk memastikan bahwa setiap segmen yang akan diproses lebih lanjut benar-benar mengandung sinyal batuk. Sistem menggunakan model YAMNet *pre-trained* pada dataset AudioSet yang mencakup 521 kelas kejadian audio. Arsitektur YAMNet dibangun berbasis MobileNetV1 yang memanfaatkan *depthwise separable convolutions* untuk efisiensi komputasi.

Proses validasi dimulai dengan memetakan indeks kelas target. Berdasarkan ontologi AudioSet yang dimuat dari *yamnet_class_map.csv*, sistem mengidentifikasi indeks k yang berkorespondensi dengan kelas label “Cough”. Sesuai dengan spesifikasi input model YAMNet, seluruh berkas audio segmen dimuat ulang dan diubah frekuensi cuplikannya menjadi 16kHz. Konversi ke 16 kHz bersifat wajib karena arsitektur YAMNet dirancang dan dilatih secara spesifik pada resolusi frekuensi tersebut. Penggunaan *sampling rate* yang berbeda akan menyebabkan ketidakcocokan dimensi input. Sinyal juga dikonversi ke dalam format *floating point* 32-bit dan dinormalisasi ke rentang $[-1.0, 1.0]$. Setiap *waveform* yang telah dinormalisasi dimasukkan ke dalam model YAMNet. Model memproses sinyal menggunakan *sliding window* dan menghasilkan matriks skor probabilitas untuk setiap kelas pada setiap *frame* waktu. Pada Gambar 3.5, ditampilkan perbandingan antara segmen batuk dan non batuk dengan visualisasi gelombang suara dan mel *spectrogram* yang di proses oleh YAMNet.



Gambar 3.5 Tahap Validasi Segmen Batuk dan Non Batuk

Secara matematis, jika $Y(x)$ adalah fungsi inferensi YAMNet yang menghasilkan matriks probabilitas P berdimensi $[T \times C]$ dimana T adalah jumlah *frame* waktu dan C adalah jumlah kelas total), maka skor probabilitas batuk S_{cough} untuk satu segmen audio dihitung dengan mengambil nilai maksimum probabilitas pada indeks kelas (k_{cough}) batuk di seluruh dimensi waktu:

$$S_{cough} = \max_{t=1}^T (P_t, k_{cough}) \quad (3.2)$$

Keterangan :

- P_t, k_{cough} adalah skor prediksi (keluaran lapisan *Softmax*) untuk kelas "Cough" pada *frame* waktu ke- t .
- Fungsi *max* digunakan untuk mendeteksi keberadaan batuk terkuat dalam segmen tersebut, meskipun durasi batuk lebih pendek dari durasi total segmen.

Untuk menentukan validitas segmen, diterapkan fungsi keputusan biner S_{cough} dengan ambang batas (*threshold*) adalah θ . Dalam penelitian ini, nilai θ ditetapkan sebesar 0.5 (probabilitas 50%). Sehingga didapatkan bahwa :

$$D(S_{cough}) = \begin{cases} 1 \text{ (valid cough)}, & \text{if } S_{cough} > \theta \\ 0 \text{ (non cough)}, & \text{if } S_{cough} \leq \theta \end{cases}$$

Segmen yang memiliki nilai ditandai pada kolom *is_cough* bernilai 1 dan disimpan dalam metadata tervalidasi untuk digunakan pada tahap ekstraksi fitur selanjutnya.

3.3.3 Kontrol Kualitas Akustik Pasca-Validasi


Meskipun segmen audio telah divalidasi sebagai "batuk" oleh model YAMNet, tidak semua segmen memiliki kualitas sinyal yang layak untuk pelatihan model *deep learning*. Segmen yang terlalu pendek, terlalu panjang, atau memiliki energi (volume) yang terlalu rendah dapat menyebabkan ketidakstabilan model atau bias pada fitur *noise*. Oleh karena itu, dilakukan tahapan kontrol kualitas audio berbasis parameter fisik sinyal.

Proses ini hanya diterapkan pada himpunan data yang telah lolos tahap validasi sebelumnya (dimana status kolom pada metadata validasi *is_cough* = 1). Segmen yang diklasifikasikan sebagai non-batuk diabaikan sepenuhnya. Setiap sinyal dimuat ulang dengan frekuensi cuplikan (f_s) target sebesar 16kHz.

Untuk setiap segmen batuk, sistem menghitung dua parameter statistik utama yaitu durasi sinyal dan energi *Root Mean Square* (RMS). Durasi Sinyal (T) dihitung berdasarkan jumlah sampel total (N) dibagi dengan frekuensi pencuplikan (f_s) dalam satuan detik. Energi *Root Mean Square* (RMS) digunakan untuk mengukur magnitudo rata-rata sinyal untuk merepresentasikan tingkat keras suara. Nilai RMS dikonversi ke skala logaritmik untuk menyesuaikan dengan persepsi pendengaran manusia dan standar pengukuran audio digital. Pada bagian ini menggunakan pustaka *Librosa*, konversi daya ke desibel dihitung sebagai:

$$L_{dB} = 10 \log_{10}(RMS^2)$$

Segmen batuk dinyatakan lolos hanya jika memenuhi ketiga kriteria batas secara simultan yaitu : durasi minimum sinyal lebih panjang dari 0.2 detik, sinyal maksimal tidak boleh melebihi 2 detik dan ambang batas energi intensitas sinyal lebih besar dari -40 dB. Pada Gambar 3.6 menampilkan distribusi energi segmen batuk pada data sekunder.



Gambar 3. 6 Distribusi Energi RMS Segmen Batuk Data Sekunder

3.4 Analisis Karakteristik Spektral Suara Batuk

Untuk memahami karakteristik intrinsik sinyal batuk setelah pra pemrosesan, dilakukan analisis distribusi energi dalam domain frekuensi. Tahapan ini bertujuan untuk mengidentifikasi komponen frekuensi dominan serta memetakan kontribusi frekuensi rendah dan tinggi relatif terhadap puncak energi utama.

Setiap segmen sinyal batuk $x[n]$ dipersiapkan untuk analisis spektrum dengan panjang jendela analisis $N = 4096$. Jika panjang sinyal kurang dari N , dilakukan teknik *zero-padding* (penambahan nilai nol) di akhir sinyal untuk meningkatkan resolusi frekuensi interpolasi pada hasil transformasi.

Sebelum transformasi, sinyal dikalikan dengan fungsi jendela Hamming untuk mengurangi kebocoran spektral (*spectral leakage*). Transformasi ke domain frekuensi dilakukan menggunakan *Fast Fourier Transform* (FFT) satu sisi dengan persamaan :

$$X[k] = \sum_{n=0}^{N-1} (x[n] \cdot w[n]) e^{-j \frac{2\pi}{N} kn} \quad (3.3)$$

Selanjutnya, Spektrum Daya (*Power Spectrum*) dihitung dari magnitudo kuadrat hasil FFT.

Agar analisis spektral invarian (tidak terpengaruh) oleh variasi volume atau *gain* perekaman antar perangkat, dilakukan normalisasi daya. Spektrum daya dibagi dengan total energi spektral sehingga jumlah total energi ternormalisasi bernilai 1 (serupa dengan fungsi massa probabilitas):

$$P[k] = \frac{P[k]}{\sum_j P[j]}$$

Dimana $P[k]$ adalah spektrum daya ternormalisasi pada bin frekuensi ke- k .

Identifikasi frekuensi puncak (*peak frequency*) merepresentasikan frekuensi dengan energi tertinggi (dominan) dalam sinyal batuk. Puncak ini ditentukan dengan mencari argumen maksimum dari spektrum daya:


$$k_{peak} = \text{argmax} (P[k])$$

$$f_{peak} = \text{freq} [k_{peak}]$$

Berdasarkan lokasi frekuensi puncak, spektrum sinyal diklasifikasikan menjadi tiga zona komponen untuk analisis kualitatif tekstur suara yaitu komponen utama, komponen rendah dan komponen tinggi. Komponen Utama adalah area di sekitar puncak energi maksimum, pada suara batuk, bagian ini berkaitan dengan frekuensi resonansi rongga dada atau *formant* pertama. Komponen Rendah yaitu area frekuensi di bawah setengah frekuensi puncak. Serta Komponen Tinggi yaitu area frekuensi di atas 1.5 kali frekuensi puncak Energi di area ini merepresentasikan detail turbulensi udara

3.5 Ekstraksi Fitur MFCC dan GFCC

Pada tahap ini, data sinyal audio batuk diubah menjadi representasi numerik menggunakan metode ekstraksi fitur MFCC dan GFCC. Tahapan ekstraksi fitur akustik MFCC dan GFCC dapat dilihat pada Gambar 3.7.



Gambar 3. 7 Tahapan Ekstraksi Fitur MFCC dan GFCC

3.5.1 Tahap Pre-Emphasis

Sebelum memasuki tahap ekstraksi fitur utama, sinyal batuk yang telah melalui proses pembersihan diproses lebih lanjut menggunakan teknik Pre-emphasis. Tahapan ini bertujuan untuk mengkompensasi karakteristik alami produksi suara manusia yang cenderung mengalami penurunan energi pada frekuensi tinggi, atau dikenal sebagai *spectral tilt*. Fenomena ini menyebabkan komponen frekuensi tinggi memiliki magnitudo yang jauh lebih kecil dibandingkan frekuensi rendah, yang dapat mengurangi efektivitas model dalam mempelajari fitur frekuensi tinggi yang krusial.


Pre-emphasis diimplementasikan sebagai filter lolos tinggi orde pertama (*first-order high-pass filter*). Proses ini dilakukan dalam domain waktu menggunakan persamaan beda (*difference equation*) sebagai berikut:

$$y[n] = x[n] - \alpha \cdot x[n - 1] \quad (3.4)$$

Keterangan :

- $y[n]$ adalah sinyal keluaran hasil pre-emphasis pada sampel ke- n
- $x[n]$ adalah sinyal masukan asli.
- α bernilai 0.97

Contoh hasil audio yang sebelum dan sesudah tahap pre-emphasis adalah pada Gambar 3.8.



Gambar 3. 8 Visualisasi Audio Sebelum dan Sesudah Tahap Pre-emphasis

3.5.2 Framing & Windowing

Sinyal suara batuk, sebagaimana sinyal wicara pada umumnya, bersifat non-stasioner, artinya properti statistik dan frekuensinya berubah-ubah terhadap waktu. Namun, metode analisis spektral seperti *Discrete Fourier Transform* (DFT) mensyaratkan sinyal input yang bersifat stasioner. Oleh karena itu, dilakukan proses Pembungkaihan (*Framing*) untuk memecah sinyal kontinu menjadi segmen-segmen pendek yang diasumsikan bersifat kuasi-stasioner (stabil dalam durasi singkat).

Proses pembungkaihan memotong sinyal pre-emphasis $y[n]$ menjadi M bingkai. Parameter waktu yang digunakan dalam penelitian ini adalah *frame length* senilai 25 ms, *hop size* senilai

10 ms dengan dengan frekuensi cuplikan (f_s) sebesar 16kHz. Dengan frekuensi cuplikan (f_s) sebesar 16kHz, jumlah sampel per bingkai (N) dan pergeseran (H) dihitung sebagai berikut:

$$N = \frac{25}{1000} \times 16.000 = 400 \text{ sampel}$$

$$H = \frac{10}{1000} \times 16.000 = 160 \text{ sampel}$$

Konfigurasi ini menghasilkan area tumpang tindih (*overlap*) antar bingkai sebesar 15 ms, yang bertujuan untuk menjaga kontinuitas informasi antar segmen dan mencegah hilangnya data di perbatasan bingkai.

Pemotongan sinyal secara langsung (*rectangular window*) dapat menyebabkan diskontinuitas amplitudo yang tajam pada tepi bingkai awal dan akhir. Dalam domain frekuensi, hal ini memicu munculnya *lobe* sisi frekuensi tinggi yang tidak diinginkan, dikenal sebagai kebocoran spektral (*spectral leakage*). Untuk memitigasi efek tersebut, setiap bingkai sinyal dikalikan dengan fungsi jendela Hamming. Fungsi ini memperhalus tepi sinyal menuju nol secara gradual.


Formula fungsi jendela Hamming didefinisikan sebagai:

$$w[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right), 0 \leq n \leq N-1 \quad (3.5)$$

Operasi penerapan *window* pada *frame* ke- i $y[n]$ dilakukan melalui perkalian *element-wise*:

$$y_{i \text{ Vektor}}[n] = y_i[n] \times w[n] \quad (3.6)$$

Hasil akhir dari tahapan ini adalah matriks bingkai berdimensi ($M \times N$) yang disimpan dalam format biner .npz (*Numpy Array*) untuk efisiensi komputasi pada tahap transformasi Fourier selanjutnya. Jika panjang sinyal lebih pendek dari satu bingkai ($< N$), dilakukan teknik *zero-padding* untuk memenuhi panjang minimum N . Visualisasi tahapan *framing & windowing* dapat dilihat pada Gambar 3.9.



Gambar 3. 9 Tahap *Framing* dan *Windowing*

3.5.3 Discrete Fourier Transform

Setelah proses *framing*, sinyal batuk masih berada dalam domain waktu (amplitudo terhadap waktu). Untuk menganalisis karakteristik spektral dari suara batuk, dilakukan transformasi ke domain frekuensi menggunakan algoritma *Discrete Fourier Transform* (DFT).

Tahap ini bertujuan untuk menghitung distribusi energi sinyal pada setiap pita frekuensi. Penelitian ini mengimplementasikan DFT secara eksplisit menggunakan operasi matriks untuk memetakan vektor waktu ke vektor frekuensi.

Diawali dengan konstruksi matriks, transformasi dilakukan berdasarkan definisi matematis DFT. Untuk sebuah *frame* sinyal $x[n]$ dengan panjang N , nilai DFT $X[k]$ diformulasikan dengan:

$$X[k] = \sum_{n=0}^{N-1} (x[n] \cdot w[n]) e^{-j \frac{2\pi}{N} kn} \quad (3.7)$$


Dimana :

- n adalah indeks sampel waktu ($0, \dots, N - 1$).
- k adalah indeks bin frekuensi ($0, \dots, N - 1$).
- $e^{-j \frac{2\pi}{N} kn}$ adalah basis eksponensial kompleks (kernel DFT).

Kernel dibentuk menjadi sebuah Matriks Twiddle berukuran $N \times N$.

Selanjutnya operasi perkalian matriks dimana input dari proses ini adalah matriks *Frames* berukuran $M \times N$ (Dimana M adalah jumlah *frame* dan N adalah panjang window). Transformasi ke domain frekuensi dilakukan secara simultan untuk seluruh *frame* menggunakan operasi perkalian matriks (dot product). Hasilnya adalah matriks X berukuran $M \times N$ yang berisi nilai kompleks $a + bi$ merepresentasikan magnitudo dan fase dari setiap komponen frekuensi pada setiap *frame*.

Kemudian *Power Spectrum* dihitung dengan menguadratkan magnitudo (nilai mutlak) dari hasil transformasi kompleks. Output dari tahapan ini adalah file tersimpan dalam format .npz berisi matriks Power Spectrum yang merepresentasikan energi spektral suara batuk dengan visualisasi pada Gambar 3.10.



Gambar 3. 10 Hasil Tahap DFT dan Plot Spektrogramnya

3.5.4 Penerapan *Filterbank*

Setelah mendapatkan *Power Spectrum*, dimensi data masih sangat besar. Selain itu, persepsi telinga manusia terhadap frekuensi tidak bersifat linier; manusia lebih sensitif terhadap perubahan pada frekuensi rendah dibandingkan frekuensi tinggi. Oleh karena itu, dilakukan pemetaan spektrum ke dalam skala logaritmik menggunakan teknik *Filterbank*.

Penelitian ini menerapkan filterbank Mel dan Gammatone dengan variasi 32 dan 40 kanal, mengacu pada standar empiris ASR yang menilai rentang 20–40 kanal sebagai titik optimal untuk keseimbangan resolusi spektral dan efisiensi komputasi (Young *et al.*, 2002; Rabiner & Juang, 1993). Oleh karena itu, konfigurasi 32 dan 40 kanal pada rentang pita lebar (*broadband*) 0–8 kHz dipilih sebagai rentang optimal untuk menjaga keseimbangan antara detail spektral


dan efisiensi model, selaras dengan konfigurasi standar (*baseline*) pada sistem pengenalan ujaran (Davis & Mermelstein, 1980; Hermansky, 1990).

3.5.4.1 Penerapan Mel-Filterbank (*Triangular Filters*)


Skala Mel memodelkan persepsi *pitch* subjektif manusia. Konversi dari frekuensi Hertz (f) ke skala Mel (m) dilakukan menggunakan persamaan:

$$m = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right) \quad (3.8)$$

Penerapan *Mel Filterbank* menggunakan serangkaian filter berbentuk segitiga (*triangular overlapping windows*) yang ditempatkan secara merata pada domain Mel. Filter ini dibangun dengan matriks bobot dimana setiap filter m memiliki respon frekuensi $H_m[k]$ yang bernilai 1 pada frekuensi tengah dan meluruh secara linier menuju 0 pada frekuensi batas tetangganya. Pada penelitian ini terdapat 2 nilai skala Mel yang diterapkan yaitu 32 dan 40 kanal dengan visualisasi respon filter pada Gambar 3.11 dan Gambar 3.12.



Gambar 3. 11 Respons Frekuensi *Mel Filterbank* 32 Kanal



Gambar 3. 12 Respons Frekuensi *Mel Filterbank* 32 Kanal


3.5.4.2 Penerapan Gammatone Filterbank (*ERB Scale*)

Berbeda dengan Mel yang didasarkan pada persepsi *pitch*, *Gammatone Filterbank* dirancang untuk meniru mekanisme hidrodinamik membran basilar pada koklea telinga dalam. Skala frekuensi yang digunakan adalah *Equivalent Rectangular Bandwidth* (ERB), yang didefinisikan sebagai:


$$f_{ERB} = 21.4 \cdot \log_{10}(1 + 0.00437 \cdot f) \quad (3.9)$$

Dalam implementasi ini, respon frekuensi filter dimodelkan menggunakan pendekatan fungsi Gaussian yang didistribusikan sepanjang skala ERB. Hal ini menghasilkan filter dengan

bentuk lonceng (*bell-shaped*) yang lebih halus dibandingkan filter segitiga pada Mel seperti tervisualisasi pada Gambar 3.13 dan 3.14 untuk masing-masing dengan nilai kanal 32 dan 40.



Gambar 3. 13 Respon Frekuensi ERB-Gammatone Filterbank 32 Kanal



Gambar 3. 14 Respon Frekuensi ERB-Gammatone Filterbank 40 Kanal

3.5.5 Kompresi Logaritmik (Log-Filterbank Energy)

Keluaran dari tahap *filterbank* sebelumnya adalah nilai energi yang berada dalam skala linear. Namun, karakteristik sinyal suara memiliki rentang dinamis (*dynamic range*) yang sangat luas. Selain itu, sistem pendengaran manusia tidak mempersepsikan kekerasan suara secara linear, melainkan secara logaritmik sesuai dengan Hukum Weber-Fechner.

Secara matematis, operasi ini didefinisikan sebagai berikut :

$$S[m] = \ln(E[m] + \epsilon) \quad (3.10)$$


Keterangan :

- $S[m]$ adalah energi log-*filterbank* pada kanal ke- m .
- $E[m]$ adalah energi *filterbank* linear dari tahap sebelumnya.
- ϵ (epsilon) adalah konstanta yang sangat kecil (1×10^{-12})

Penambahan konstanta ϵ diperlukan untuk menjaga stabilitas numerik. Karena fungsi logaritma tidak terdefinisi pada nilai 0 ($\ln(0) = -\infty$), ϵ mencegah terjadinya *error* komputasi pada segmen sinyal yang hening total (dimana $E[m] = 0$).

Proses ini diterapkan pada keempat variasi fitur yang sedang diteliti (Mel-32, Mel-40, Gammatone-32, dan Gammatone-40). Hasil akhirnya berupa matriks fitur *Log-Mel Spectrogram* dan *Log-Gammatone Spectrogram* yang digunakan sebagai input untuk tahap

berikutnya. Visualisasi *Log-Mel Spectrogram* dan *Log-Gammatone Spectrogram* seperti pada Gambar 3.15.



Gambar 3. 15 *Log-Mel Spectrogram* dan *Log-Gammatone Spectrogram*

3.5.6 Discrete Cosine Transform (DCT)

Fitur *Log-Filterbank Energies* yang dihasilkan pada tahap sebelumnya memiliki korelasi yang tinggi antar kanal frekuensi yang berdekatan (karena adanya *overlap* pada *filterbank*). Untuk mendapatkan representasi fitur yang lebih padat (*compact*) dan saling tidak berkorelasi (*uncorrelated*), dilakukan transformasi menggunakan Discrete Cosine Transform (DCT). Penerapan DCT pada log-spektrum ini membawa sinyal dari domain frekuensi ke domain Quefrency (istilah anagram dari *Frequency*), yang dikenal sebagai domain Cepstrum. Proses ini menghasilkan dua jenis fitur utama bergantung pada inputnya yaitu MFCC (*Mel-Frequency Cepstral Coefficients*) jika inputnya adalah *Log-Mel* dan GFCC (*Gammatone-Frequency Cepstral Coefficients*) jika inputnya adalah *Log-Gammatone*.

Penelitian ini menggunakan algoritma DCT Tipe-II dengan normalisasi ortogonal. Secara matematis, untuk sebuah *frame* dengan energi logaritma $S[m]$ (dimana $m = 0, \dots, M - 1$ adalah indeks *filterbank*), koefisien cepstral $C[n]$ dihitung sebagai:

$$C[n] = \sum_{m=0}^{M-1} S[m] \cdot \cos \left[\frac{\pi}{M} \left(m + \frac{1}{2} \right) n \right] \quad (3.11)$$


Keterangan :

- n adalah indeks koefisien cepstral.
- M adalah jumlah kanal *filterbank* (32 atau 40).
- $C[n]$ adalah hasil fitur MFCC/GFCC.

Dalam penelitian ini, dilakukan variasi pengambilan jumlah koefisien untuk mencari konfigurasi optimal sebagaimana pada Tabel 3.2. Tahap DCT menghasilkan MFCC dan GFCC sebagaimana pada Gambar 3.16.

Tabel 3. 2 Variasi Jumlah Koefisien DCT

Nilai Jumlah Koefisien	Sifat
13	Standar umum dalam pengenalan suara, merepresentasikan bentuk dasar formem suara.
26	Memberikan detail spektral yang lebih rinci.
39	Mengambil hampir seluruh informasi dari <i>filterbank</i> .



Gambar 3. 16 MFCC dan GFCC dengan Koefisien 13

3.6 Augmentasi Data

Dataset pada penelitian ini memiliki distribusi kelas yang tidak seimbang. Kondisi ini dapat menyebabkan model *deep learning* menjadi bias, cenderung memprediksi kelas mayoritas dan mengabaikan kelas minoritas. Untuk mengatasi hal tersebut, penelitian ini menerapkan teknik Oversampling pada kelas minoritas menggunakan metode SpecAugment. Berbeda dengan augmentasi audio tradisional yang memanipulasi sinyal suara mentah (seperti *pitch shifting* atau *time stretching*), SpecAugment bekerja langsung pada fitur domain waktu-frekuensi.


Metode ini memodifikasi fitur input secara stokastik tanpa mengubah label semantiknya, sehingga memaksa model untuk belajar fitur yang lebih *robust* dan tidak hanya menghafal pola tertentu. Tiga operasi utama yang diterapkan adalah *time masking*, *frequency masking* dan *gaussian noise injection*.

3.7 Arsitektur dan Pelatihan Model *Deep Learning*

Penelitian ini menerapkan dua pendekatan *Deep Learning* yang berbeda untuk mengeksplorasi karakteristik sinyal batuk, yaitu *Long Short-Term Memory* (LSTM) untuk analisis pola sekuensial dan *Convolutional Neural Network* (CNN) untuk analisis pola spasial


spektral. Kedua model dilatih menggunakan input matriks fitur MFCC dan GFCC dengan skema pembagian data 80% untuk pelatihan (*training*) dan 20% untuk pengujian (*testing*).

Model LSTM dirancang untuk menangkap dinamika temporal jangka panjang dari sinyal batuk. Sebagaimana divisualisasikan pada Gambar 3.16, arsitektur ini terdiri dari tiga lapisan LSTM yang disusun secara bertingkat (*stacked*) dengan jumlah unit masing-masing 64, 128, dan 256. Setiap lapisan dikonfigurasi dengan *return_sequences=True* untuk mempertahankan integritas informasi urutan waktu dari lapisan awal hingga akhir. Untuk menjaga stabilitas pelatihan dan mempercepat konvergensi, diterapkan lapisan *Batch Normalization* pada tahap awal input. Selain itu, teknik regularisasi berupa *Dropout* dengan rasio 0,2 disisipkan sebelum lapisan *Dense* akhir untuk memitigasi risiko *overfitting*. Proses klasifikasi final dilakukan oleh satu neuron pada lapisan output dengan fungsi aktivasi *Sigmoid* yang menghasilkan probabilitas kelas TB atau Non-TB.



Gambar 3. 17 Arsitektur Model LSTM

Arsitektur CNN memperlakukan input fitur sebagai representasi citra 2D (frekuensi x waktu) untuk mengekstraksi korelasi tekstur spektral. Detail arsitektur model dapat dilihat pada Gambar 3.18. Proses ekstraksi fitur dilakukan melalui serangkaian blok konvolusi (*Conv2D*) dengan filter bertingkat mulai dari 32, 64, 128, hingga 256 filter berukuran kernel 3x3. Setiap blok konvolusi diikuti oleh lapisan *MaxPooling2D* untuk mereduksi dimensi fitur, di mana pada lapisan yang lebih dalam, *pooling* dibatasi hanya pada dimensi waktu guna mempertahankan resolusi frekuensi yang memuat informasi formant penting. Strategi regularisasi diterapkan secara lebih agresif dengan *Dropout* 0,3 pada blok konvolusi dan *Dropout* 0,5 pada lapisan *Fully Connected* (Dense 128 unit) sebelum masuk ke lapisan output.



Gambar 3. 18 Arsitektur Model CNN

3.8 Evaluasi Matriks Klasifikasi

Untuk mengukur efektivitas model CNN dan LSTM dalam mengklasifikasikan suara batuk menjadi kelas positif (TBC) dan negatif (Non-TBC), digunakan serangkaian metrik evaluasi standar yang diturunkan dari Confusion Matrix. Metrik-metrik yang digunakan dalam penelitian ini adalah sebagai berikut:

1. *Confusion Matrix*

Confusion matrix membandingkan label prediksi model dengan label kebenaran dasar (*ground truth*). Tabel ini terdiri dari empat komponen utama:

- *True Positive* (TP): Sampel TBC yang diprediksi dengan benar sebagai TBC.
- *True Negative* (TN): Sampel sehat/negatif yang diprediksi dengan benar sebagai sehat.
- *False Positive* (FP): Sampel sehat yang salah diprediksi sebagai TBC.
- *False Negative* (FN): Sampel TBC yang salah diprediksi sebagai sehat.

2. *Accuracy* (Akurasi)

Akurasi mengukur rasio prediksi yang benar secara keseluruhan terhadap total sampel data uji.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

3. *Sensitivity* (*Recall*)

Sensitivitas mengukur kemampuan model dalam menemukan kasus positif.

$$Recall = \frac{TP}{TP + FN}$$

4. *Precision* (Presisi)

Presisi mengukur seberapa akurat model saat menyatakan seseorang positif.

$$Precision = \frac{TP}{TP + FP}$$

5. *F1-Score*

F1-Score adalah rata-rata harmonik antara Presisi dan Recall. Metrik ini memberikan representasi tunggal dari keseimbangan kinerja model.

$$F1 - Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

6. *Receiver Operating Characteristic* (ROC)

Kurva ROC menggambarkan performa model klasifikasi pada berbagai ambang batas (*threshold*) keputusan. Sumbu horizontal adalah *False Positive Rate* (FPR) dan sumbu vertikal adalah *True Positive Rate* (TPR/Recall).

7. *Area Under Curve* (AUC)

Nilai AUC merepresentasikan kemampuan separabilitas model. Semakin mendekati 1.0, semakin baik model dalam membedakan suara batuk TBC dan Non-TBC.


BAB 4 HASIL DAN PEMBAHASAN

4.1 Deskripsi Data Penelitian

Pada penelitian ini, digunakan dua jenis dataset untuk melatih dan menguji model, yaitu dataset sekunder yang diakses secara publik (CIRDZ) dan data primer yang dikumpulkan secara mandiri di Poli TB DOTS RSUD. Tahap awal yang dilakukan adalah eksplorasi data untuk memahami karakteristik sinyal batuk.


4.1.1 Dataset Sekunder (CIRDZ)

Berdasarkan hasil eksplorasi pada dataset CIRDZ, dilakukan analisis terhadap durasi rekaman batuk untuk memastikan input data memiliki panjang yang seragam atau untuk menentukan strategi *padding/truncating*.




Gambar 4. 1 Distribusi Durasi Batuk Pasien Dataset *Cleaned* Sekunder

Berdasarkan Gambar 4.1, dapat dilihat distribusi durasi batuk antara kelas negatif (non-TB) dan positif (TB). Mayoritas data, baik pada kelas positif maupun negatif, memiliki rentang durasi antara 0.5 hingga 1.0 detik, dengan jumlah sampel sebanyak 3.121 untuk kelas negatif dan 565 untuk kelas positif. Data dengan durasi sangat pendek (< 0.5 detik) dan durasi panjang (> 1.5 detik) memiliki frekuensi kemunculan yang jauh lebih sedikit. Kondisi ini mengisyaratkan perlunya pembatasan *input shape* pada rentang durasi tersebut untuk menyeimbangkan antara kelengkapan informasi dan reduksi *noise* sehingga dilakukan penerapan metode *cleaned control* yang membatasi pada durasi batuk minimal yaitu 0.2 detik dan maksimal 2.0 detik, seperti terdistribusi pada Gambar 4.2. Di sisi lain, dominasi data negatif yang menyebabkan *class imbalance* diatasi dengan augmentasi data dengan persebaran pada Gambar 4.3.




Gambar 4. 2 Distribusi Durasi Batuk Pasien Dataset *Cleaned Control* Sekunder




Gambar 4. 3 Distribusi Data Sekunder Batuk Setelah dan Sebelum Augmentasi

4.1.2 Analisis Dataset Primer

Data primer dalam penelitian ini diperoleh melalui proses akuisisi data secara langsung yang dilakukan di Rumah Sakit Univeristas Airlangga pada periode Oktober 2025 hingga November 2025. Pengambilan data dilakukan dengan mengikuti protokol etika penelitian dan mendapatkan persetujuan (*informed consent*) dari partisipan. Proses pengumpulan data difokuskan pada subjek yang memenuhi kriteria inklusi, yaitu pasien yang terdiagnosis Tuberkulosis (TB) berdasarkan hasil uji klinis (seperti Tes Cepat Molekuler/TCM atau BTA positif) serta subjek sehat atau non-TB sebagai kontrol. Perekaman suara batuk dilakukan menggunakan perangkat dengan sensor mic INMP441S dengan format penyimpanan audio .wav.




Gambar 4. 4 Distribusi Demografi Dataset Primer



Gambar 4. 5 Distribusi Durasi Batuk Pasien Dataset Primer

Berdasarkan karakteristik demografinya yang tervisualisasikan pada Gambar 4.4, dataset ini mencakup dari 21 data. Data sebaran menunjukkan adanya ketimpangan yang signifikan antara kelas non-TB dan TB, di mana terdapat 9 non-TB dan 12 yang terkonfirmasi TB. Distribusi jenis kelamin terdiri dari 11 perempuan dan 10 laki-laki. Pada identifikasi durasi suara batuk primer didapatkan rentang berkisar pada 0.5 detik hingga 1.5 detik. Durasi tersebut masih berada pada rentang data sekunder yang digunakan untuk membuat model klasifikasi.

4.1.3 Visualisasi Sinyal Data Sekunder dan Primer



Gambar 4. 6 Visualisasi Audio Sekunder dan Primer dalam Bentuk *Raw* dan *Segmented*

Visualisasi sinyal dalam domain waktu (*waveform*) dan frekuensi (*spectrogram*) pada Gambar 4.6 memperlihatkan perbedaan karakteristik kualitas antara kedua sumber data. Data sekunder (CIRDZ) menunjukkan pola sinyal dengan *signal-to-noise ratio* (SNR) yang tinggi dan distribusi energi spektral yang terfokus, mengindikasikan kondisi perekaman yang relatif steril. Sebaliknya, visualisasi data primer memperlihatkan adanya fluktuasi amplitudo pada area *silence* dan sebaran artefak pada spektrogram yang merepresentasikan *background noise* akibat lingkungan akuisisi yang tidak terstandarisasi. Perbedaan karakteristik ini menegaskan pentingnya penerapan pra-pemrosesan seperti *denoising* dan normalisasi agar model memiliki ketahanan (*robustness*) yang baik terhadap variabilitas sinyal pada data riil.


4.2 Evaluasi Kinerja Model pada Dataset Sekunder (CIRDZ)

Kuantifikasi dari hasil pengujian model CNN dengan 12 varian ekstraksi fitur tertampil pada Tabel 4.1, yang menyajikan komparasi performa model berdasarkan variasi jenis fitur dan jumlah koefisien filter. Untuk mempermudah interpretasi signifikansi hasil, tabel tersebut menggunakan anotasi warna, di mana warna biru menandai konfigurasi dengan performa klasifikasi terbaik), sedangkan warna oranye mengindikasikan konfigurasi dengan performa suboptimal atau terendah. Anotasi biru pada model CNN untuk data sekunder didapatkan pada varian MFCC dengan 32 kanal dan 39 koefisien serta GFCC dengan 40 kanal dan 39 koefisien, yang mencatatkan akurasi tertinggi masing-masing 93%. Kemudian untuk hasil yang kuarng optimal pada model CNN Sekunder yaitu pada varian MFCC dengan 40 kanal dan 13 koefisien serta GFCC dengan 32 kanal dan 39 koefisien, yang mencatatkan akurasi masing-masing sebesar 90% dan 91%.


Tabel 4. 1 Hasil Performa Model CNN pada Data Sekunder

Variant	Accuracy	Precision	Recall	F1	AUC
MFCC32_13	0.92	0.96	0.88	0.92	0.98
MFCC32_26	0.93	0.96	0.87	0.91	0.98
MFCC32_39	0.93	0.94	0.92	0.93	0.99
MFCC40_13	0.90	0.90	0.90	0.90	0.97
MFCC40_26	0.92	0.93	0.91	0.92	0.98
MFCC40_39	0.92	0.92	0.92	0.92	0.98
GFCC32_13	0.91	0.94	0.90	0.92	0.97
GFCC32_26	0.92	0.95	0.90	0.92	0.98
GFCC32_39	0.91	0.94	0.88	0.91	0.98
GFCC40_13	0.91	0.91	0.92	0.91	0.97
GFCC40_26	0.92	0.94	0.90	0.92	0.98
GFCC40_39	0.93	0.95	0.90	0.92	0.98


Berdasarkan hasil visualisasi representasi spevtogram dan koefisiesn yang ditunjukkan pada Gambar 4.7 dan Gambar 4.9 terlihat perbedaan karakteristik antara fitur MFCC dan GFCC dalam menangkap pola sinyal batuk. Pada visualisasi fitur MFCC, distribusi energi spektral cenderung terkompresi pada frekuensi rendah akibat penggunaan skala Mel yang bersifat logaritmik, sehingga detail harmonik pada frekuensi menengah sering kali terdistorsi, terutama pada data primer yang memiliki *noise floor* berbeda. Sebaliknya, visualisasi fitur GFCC memperlihatkan resolusi spektral yang lebih detail dan terpisah secara jelas pada pita frekuensi kritis, hal ini disebabkan oleh karakteristik *Gammatone Filterbank* yang meniru respons impuls membran basilar koklea, sehingga mampu mempertahankan integritas sinyal batuk. Kemudian pada Gambar 4.8 dan Gambar 4.10 menampilkan grafik akurasi dan *loss* dari pengujian model.




Gambar 4. 7 Visualisasi Hasil Ekstraksi Fitur Sekunder MFCC Kanal 32 Koefisien 39



Gambar 4. 8 (a) Confusion Matriks (b) Grafik Akurasi (c) Grafik Loss Hasil Ekstraksi Fitur Sekunder MFCC Kanal 32 Koefisien 39



Gambar 4. 9 Visualisasi Hasil Ekstraksi Fitur Sekunder GFCC Kanal 40 Koefisien 39




Gambar 4. 10 (a) Confusion Matriks (b) Grafik Akurasi (c) Grafik Loss Hasil Ekstraksi Fitur Sekunder GFCC Kanal 40 Koefisien 39


Pada Tabel 4.2 menampilkan hasil performa pengujian model LSTM pada data sekunder didapatkan pada varian MFCC dengan 32 kanal dan 39 koefisien serta GFCC dengan 32 kanal dan 26 koefisien, yang mencatatkan akurasi tertinggi masing-masing 96%. Kemudian untuk hasil yang kurang optimal pada model LSTM Sekunder yaitu pada varian MFCC dengan 32 kanal dan 13 koefisien serta GFCC dengan 40 kanal dan 13 koefisien, yang mencatatkan akurasi masing-masing sebesar 94% dan 90%.

Tabel 4. 2 Hasil Performa Model LSTM Data Sekunder


Variant	Accuracy	Precision	Recall	F1	AUC
MFCC32_13	0.94	0.96	0.92	0.94	0.99
MFCC32_26	0.95	0.96	0.95	0.95	0.99
MFCC32_39	0.96	0.97	0.98	0.96	0.99
MFCC40_13	0.92	0.91	0.93	0.92	0.97
MFCC40_26	0.95	0.94	0.97	0.95	0.98
MFCC40_39	0.95	0.92	0.97	0.95	0.99
GFCC32_13	0.91	0.92	0.94	0.93	0.96
GFCC32_26	0.96	0.96	0.96	0.96	0.99
GFCC32_39	0.96	0.94	0.98	0.96	0.99
GFCC40_13	0.90	0.91	0.90	0.90	0.97
GFCC40_26	0.94	0.92	0.97	0.95	0.99
GFCC40_39	0.96	0.94	0.97	0.96	0.99




Gambar 4. 11 Visualisasi Hasil Ekstraksi Fitur Sekunder MFCC Kanal 32 Koefisien 39



Gambar 4. 12 (a) Confusion Matriks (b) Grafik Akurasi (c) Grafik Loss Hasil Ekstraksi Fitur Sekunder MFCC Kanal 32 Koefisien 39



Gambar 4. 13 Visualisasi Hasil Ekstraksi Fitur Sekunder GFCC Kanal 32 Koefisien 26



Gambar 4. 14 (a) Confusion Matriks (b) Grafik Akurasi (c) Grafik Loss Hasil Ekstraksi Fitur Sekunder GFCC Kanal 32 Koefisien 26

Berdasarkan pengujian pada data sekunder didapatkan hasil akurasi yang lebih tinggi yaitu pada model LSTM dibandingkan dengan CNN. Variasi fitur yang memiliki keunggulan dalam kedua model didapatkan pada MFCC dengan 32 kanal dan 39 koefisien, sedangkan untuk hasil yang kurang optimal didapatkan dari MFCC dan GFCC dengan 13 koefisien, hal tersebut dikarenakan 13 koefisien cenderung digunakan untuk mengolah suara bicara.

4.3 Evaluasi Kinerja Model pada Dataset Primer Sebelum Augmentasi

Evaluasi performa model pada tahap awal dilakukan menggunakan dataset murni tanpa penerapan teknik augmentasi. Nilai evaluasi dari hasil pengujian model CNN dengan 12 varian ekstraksi fitur dengan data tidak diaugmentasi untuk data primer tertampil pada Tabel 4.3 dan untuk model LSTM pada Tabel 4.4.

Tabel 4. 3 Hasil Model CNN Data Primer Sebelum Augmentasi

Variant	Accuracy	Precision	Recall	F1	AUC
MFCC32_13	0.62	0.0	0.0	0.0	0.575
MFCC32_26	0.62	0.0	0.0	0.0	0.625
MFCC32_39	0.69	1.0	0.2	0.33	0.6
MFCC40_13	0.69	1.0	0.2	0.33	0.925
MFCC40_26	0.69	1.0	0.2	0.33	0.725
MFCC40_39	0.61	0.0	0.0	0.0	0.8
GFCC32_13	0.53	0.0	0.0	0.0	0.1
GFCC32_26	0.61	0.0	0.0	0.0	0.575
GFCC32_39	0.61	0.0	0.0	0.0	0.525
GFCC40_13	0.53	0.0	0.0	0.0	0.65
GFCC40_26	0.61	0.0	0.0	0.0	0.7
GFCC40_39	0.61	0.0	0.0	0.0	0.575

Tabel 4. 4 Hasil Model LSTM Data Primer Sebelum Augmentasi

Variant	Accuracy	Precision	Recall	F1	AUC
MFCC32_13	0.62	0.5	0.125	0.2	0.4
MFCC32_26	0.62	0.0	0.0	0.0	0.25
MFCC32_39	0.62	0.0	0.125	0.22	0.625
MFCC40_13	0.69	1.0	0.25	0.4	0.425
MFCC40_26	0.54	0.33	0.125	0.18	0.275
MFCC40_39	0.54	0.33	0.125	0.18	0.25
GFCC32_13	0.38	0.0	0.0	0.0	0.125
GFCC32_26	0.62	0.0	0.0	0.0	0.35
GFCC32_39	0.62	0.0	0.0	0.0	0.48
GFCC40_13	0.62	0.0	0.0	0.0	0.40
GFCC40_26	0.54	0.0	0.0	0.0	0.45
GFCC40_39	0.62	0.0	0.0	0.0	0.375

Terkait perbandingan karakteristik fitur, inkonsistensi performa GFCC pada data primer di mana beberapa konfigurasi menghasilkan nilai presisi atau *recall* nol sebelum augmentasi dikarenakan jumlah dan kualitas datanya. Meskipun Liu *et al.* (2013) serta Zhao & Wang (2013) menyatakan bahwa GFCC memiliki keunggulan teoretis dibandingkan MFCC dalam kondisi lingkungan dengan derau berat, efektivitas fitur ini sangat bergantung pada ketersediaan jumlah data yang memadai dan distribusi yang representatif. Pada kondisi dataset yang terbatas dan tidak seimbang (*imbalanced*) seperti data primer penelitian ini, performa GFCC terbukti lebih fluktuatif dibandingkan MFCC yang menawarkan konsistensi lebih baik.

4.4 Evaluasi Kinerja Model pada Dataset Primer Setelah Augmentasi

Dari model yang sudah didapatkan pada data sekunder, kemudian model diuji pada data primer. Data primer dilakukan proses augmentasi agar jumlah data seimbang. Kuantifikasi dari hasil pengujian model CNN dengan 12 varian ekstraksi fitur tertampil pada Tabel 4.3 dan untuk model LSTM pada Tabel 4.4, yang menyajikan komparasi performa model berdasarkan variasi jenis fitur dan jumlah koefisien filter. Untuk mempermudah interpretasi signifikansi hasil, tabel tersebut menggunakan anotasi warna, di mana warna biru menandai konfigurasi dengan performa klasifikasi terbaik), sedangkan warna oranye mengindikasikan konfigurasi dengan performa suboptimal atau terendah. Performa paling unggul untuk pada model CNN dan LSTM untuk data primer didapatkan pada varian MFCC dengan 40 kanal, yang mencatatkan akurasi tertinggi masing-masing yaitu 75% dan 0.625%.

Tabel 4. 5 Hasil Model CNN Data Primer Setelah Augmentasi


Variant	Accuracy	Precision	Recall	F1	AUC
MFCC32_13	0.6875	1.0	0.375	0.54	0.734375
MFCC32_26	0.6875	1.0	0.375	0.54	0.765625
MFCC32_39	0.75	1.0	0.5	0.66	0.734375
MFCC40_13	0.75	1.0	0.5	0.66	0.953125
MFCC40_26	0.75	1.0	0.5	0.66	0.8125
MFCC40_39	0.6875	1.0	0.375	0.54	0.875
GFCC32_13	0.625	0.75	0.375	0.5	0.453125
GFCC32_26	0.625	1.0	0.25	0.4	0.71875
GFCC32_39	0.6875	1.0	0.375	0.54	0.703125
GFCC40_13	0.625	0.75	0.375	0.5	0.78125
GFCC40_26	0.6875	1.0	0.375	0.54	0.734375
GFCC40_39	0.6875	1.0	0.375	0.54	0.765625

Tabel 4. 6 Hasil Model LSTM Data Primer Setelah Augmentasi


Variant	Accuracy	Precision	Recall	F1	AUC
MFCC32_13	0.5	0.5	0.125	0.2	0.5625
MFCC32_26	0.5	0.0	0.0	0.0	0.46875
MFCC32_39	0.5625	1.0	0.125	0.22	0.75
MFCC40_13	0.625	1.0	0.25	0.4	0.5625
MFCC40_26	0.4375	0.33	0.125	0.18	0.203125
MFCC40_39	0.4375	0.33	0.125	0.18	0.1875
GFCC32_13	0.4375	0.4	0.25	0.31	0.265625
GFCC32_26	0.5625	1.0	0.125	0.22	0.4375
GFCC32_39	0.5	0.0	0.0	0.0	0.46875
GFCC40_13	0.5625	1.0	0.125	0.22	0.484375
GFCC40_26	0.4375	0.0	0.0	0.0	0.4375
GFCC40_39	0.5	0.0	0.0	0.0	0.375

Berdasarkan hasil yang didapatkan menempatkan arsitektur CNN dengan input MFCC 40 kanal dan 13 koefisien sebagai konfigurasi dengan akurasi tertinggi pada data primer selaras dengan temuan literatur terdahulu. Balamurali *et al.* (2021) menghasilkan bahwa representasi berbasis *Mel-spectrogram* dan MFCC menunjukkan stabilitas yang lebih tinggi ketika dipadukan dengan arsitektur CNN untuk tugas klasifikasi patologi pernapasan dengan etiologi


yang beragam. Hal ini juga diperkuat oleh studi Suda (2023), yang menyoroti kinerja superior *2D-CNN* berbasis *Mel-spectrogram* dalam deteksi Tuberkulosis, di mana model tersebut terbukti lebih tangguh dibandingkan model berbasis struktur temporal murni yang cenderung sensitif terhadap variasi domain rekaman.



Gambar 4. 15 Visualisasi Hasil Ekstraksi Fitur MFCC 40 Kanal dan 13 Koefisien pada Data Primer Positif



Gambar 4. 16 Visualisasi Hasil Ekstraksi Fitur MFCC 40 Kanal dan 13 Koefisien pada Data Primer Negatif




Gambar 4. 17 Confusion Matriks untuk Data Primer (a) Model CNN (b) Model LSTM

Berdasarkan pengujian pada data primer didapatkan hasil akurasi yang lebih tinggi yaitu pada model CNN dibandingkan dengan LSTM. Variasi fitur yang memiliki keunggulan dalam kedua model didapatkan pada MFCC dengan 40 kanal dan 13 koefisien. Hal ini berkebalikan dengan pengujian data sekunder. Perbedaan hasil pengujian ini juga dikarenakan spesifikasi alat perekaman pada masing-masing kondisi yang berbeda.

Ketidakimbangan nilai antara nilai AUC yang tinggi (>0.90) namun akurasi yang moderat (75%) pada pengujian data primer mengindikasikan adanya *domain shift*, sebuah tantangan yang juga dilaporkan secara luas dalam penelitian klasifikasi batuk TB dan penyakit paru lainnya. Model yang dilatih pada data sekunder seringkali mengalami kegagalan kalibrasi probabilitas saat diuji pada rekaman klinis lapangan yang memiliki tingkat *noise* lebih tinggi. Berbagai studi menyarankan bahwa kesenjangan performa ini dapat dimitigasi tanpa mengubah arsitektur model, melainkan melalui strategi penyesuaian ambang batas keputusan (*threshold adjustment*), teknik rekalisasi probabilitas, serta pengayaan data pada *target-domain*.


4.5 Analisi Komparasi Distribusi Fitur MFCC dan GFCC

Analisis histogram menunjukkan bahwa fitur suara batuk TB memiliki distribusi yang lebih sempit dibandingkan kelas Non-TB yang lebar, menandakan adanya pola akustik akibat kesamaan patologi paru. Meskipun fitur GFCC menunjukkan keterpisahan visual yang lebih baik, korelasinya dengan akurasi model tidak selalu linear karena *Deep Learning* memproses pola sekuensial yang kompleks di luar parameter distribusi statis semata. Tingginya akurasi pada data sekunder dikarenakan lingkungan perekaman terkondisi yang menghasilkan distribusi Gaussian ideal, sedangkan gangguan distribusi pada data primer disebabkan oleh lingkungan tidak terkondisi sehingga terjadi penurunan performa.




Gambar 4. 18 Grafik Distribusi MFCC 32 Kanal dan 13 Koefisien

Gambar 4.18 dan Gambar 4.19 memperlihatkan distribusi rata-rata fitur MFCC yang telah dinormalisasi untuk masing-masing berkas batuk TB (positif) dan non-TB (negatif). Pada konfigurasi MFCC32_39, histogram kedua kelas membentuk pola yang mendekati distribusi normal dengan puncak yang tajam di sekitar nilai nol, menandakan bahwa representasi fitur menjadi lebih homogen dan sesuai dengan asumsi Gaussian yang umum digunakan dalam optimisasi model *deep learning*. Sebaliknya, konfigurasi MFCC32_13 menunjukkan sebaran yang lebih lebar dan cenderung multimodal, terutama pada kelas TB, yang mengindikasikan bahwa jumlah koefisien yang terlalu sedikit menghasilkan representasi yang kurang stabil dan sensitif terhadap variasi antar sampel.




Gambar 4. 19 Grafik Distribusi MFCC 32 Kanal dan 39 Koefisien

Gambar 4.20 dan Gambar 4.21 memperlihatkan distribusi rata-rata fitur GFCC yang telah dinormalisasi untuk masing-masing berkas batuk TB (positif) dan non-TB (negatif). Pada sisi lain, distribusi GFCC32_13 dan GFCC32_26 juga memperlihatkan kecenderungan normal, namun dengan ekor distribusi yang lebih berat pada nilai positif untuk kelas TB. Hal ini sejalan dengan karakteristik GFCC yang memanfaatkan *Gammatone Filterbank* berbasis skala ERB sehingga lebih peka terhadap perubahan energi pada pita frekuensi sensitif. Pola ini menunjukkan bahwa GFCC mampu mempertahankan perbedaan halus pada sinyal batuk patologis, meskipun tumpang tindih antar kelas masih cukup besar pada representasi rata-rata global.



Gambar 4. 20 Grafik Distribusi GFCC 32 Kanal dan 13 Koefisien



Gambar 4. 21 Grafik Distribusi GFCC 32 Kanal dan 26 Koefisien

Secara keseluruhan, distribusi rata-rata fitur pada menunjukkan bahwa MFCC dengan jumlah koefisien yang lebih besar (MFCC32_39) menghasilkan sebaran yang paling mendekati distribusi normal dan memberikan kinerja tertinggi pada model CNN dan LSTM, khususnya pada data sekunder. Hal ini mengindikasikan bahwa peningkatan kapasitas representasi MFCC membantu model dalam membedakan pola batuk TB dan non-TB. Di sisi lain, GFCC menunjukkan distribusi yang relatif stabil dan lebih tahan terhadap variasi spektral, yang selaras dengan sifatnya yang lebih *noise-robust* dan biologis. Namun, tumpang tindih antara distribusi kelas pada domain ini masih cukup besar sehingga keunggulan performa GFCC terhadap MFCC belum konsisten di seluruh konfigurasi.

BAB 5 KESIMPULAN DAN SARAN

5.1 Kesimpulan

Model klasifikasi tuberkulosis berbasis suara batuk yang dikembangkan mampu mencapai performa tinggi pada data sekunder CIRDZ melalui kombinasi ekstraksi fitur MFCC dan GFCC dengan model *deep learning* CNN dan LSTM, ditunjukkan oleh akurasi hingga 96% dan nilai AUC yang mendekati 1 pada konfigurasi tertentu. Variasi jumlah kanal *filterbank* dan koefisien DCT terbukti memengaruhi kualitas representasi spektral, di mana konfigurasi MFCC 32 kanal dengan 39 koefisien memberikan distribusi fitur yang lebih mendekati normal dan menghasilkan kinerja terbaik pada sebagian besar skenario pelatihan dan pengujian. Hal ini menunjukkan bahwa peningkatan kapasitas representasi MFCC setelah optimasi parameter mampu menangkap perbedaan pola spektral batuk TB dan non-TB secara lebih efektif.

Di sisi lain, GFCC yang berbasis *Gammatone Filterbank* pada skala ERB menunjukkan karakteristik lebih robust terhadap variasi spektral dan *noise*, dengan distribusi fitur yang stabil dan ekor distribusi lebih berat pada kelas TB, namun keunggulan performanya dibanding MFCC belum konsisten di seluruh konfigurasi dan skenario pengujian. Meskipun demikian, hasil komparasi mengindikasikan bahwa GFCC tetap relevan sebagai kandidat fitur alternatif atau komplementer terutama pada lingkungan perekaman yang lebih bising, sehingga kombinasi pemilihan fitur dan arsitektur model menjadi faktor kunci dalam perancangan sistem klasifikasi berbasis batuk.

Pengujian pada data primer yang direkam dengan perangkat INMP441S di lingkungan klinis nyata menunjukkan adanya penurunan performa dibandingkan data sekunder, dengan akurasi terbaik sekitar 75% pada model CNN dengan konfigurasi MFCC 40 kanal dan 13 koefisien serta kinerja LSTM yang relatif lebih rendah. Perbedaan ini menggarisbawahi tantangan *domain shift* antara data sekunder terstandar dan data primer di dunia nyata, termasuk perbedaan karakteristik *noise*, perangkat perekaman, serta jumlah sampel yang terbatas. Hasil ini menegaskan bahwa walaupun model yang dilatih pada data sekunder memiliki performa tinggi, generalisasi ke kondisi klinis aktual masih perlu diperkuat melalui strategi adaptasi domain, peningkatan volume data primer, dan penyesuaian pipeline pra-pemrosesan.

Secara keseluruhan, penelitian ini berhasil menjawab rumusan masalah dengan menunjukkan bahwa pemilihan konfigurasi fitur MFCC dan GFCC yang tepat, disertai arsitektur *deep learning* yang sesuai, mampu menghasilkan sistem klasifikasi batuk TB dan non-TB dengan performa baik pada data sekunder serta performa moderat pada data primer. Penelitian ini juga memberikan dasar ilmiah bahwa pengaturan hiperparameter seperti jumlah kanal *filterbank*, jumlah koefisien DCT, dan pemilihan model CNN atau LSTM memiliki dampak signifikan terhadap kemampuan model dalam memisahkan pola akustik batuk patologis dan non-patologis, sehingga dapat menjadi referensi untuk pengembangan sistem pra-skrining TB yang lebih akurat dan aplikatif.

5.2 Saran

Pengembangan penelitian selanjutnya dapat menambah jumlah dan keragaman data primer dari berbagai fasilitas kesehatan dengan protokol perekaman yang lebih terstandar, serta menerapkan teknik adaptasi domain dan regularisasi lanjutan agar model lebih robust terhadap variasi lingkungan dan perangkat perekaman. Selain itu, eksplorasi kombinasi fitur antara MFCC, GFCC, dan fitur spektral lain, serta pengujian arsitektur *deep learning* yang lebih kompleks seperti CNN-LSTM hibrid atau transformer berbasis sekuens dapat dilakukan untuk meningkatkan generalisasi model, khususnya pada kondisi klinis nyata dengan *noise* tinggi dan keterbatasan sumber daya.

(Halaman ini sengaja dikosongkan)

DAFTAR PUSTAKA

- Abdul, Z. K., & Al-Talabani, A. K. (2022). Mel Frequency Cepstral Coefficient and its Applications: A Review. *IEEE Access*, 10(November), 122136–122158. <https://doi.org/10.1109/ACCESS.2022.3223444>
- Ayoub, B., Jamal, K., & Arsalane, Z. (2016). Gammatone frequency cepstral coefficients for speaker identification over VoIP networks. *2016 International Conference on Information Technology for Organizations Development, IT4OD 2016*, 1–5. <https://doi.org/10.1109/IT4OD.2016.7479293>
- Balamurali, B. T., Hee, H. I., Kapoor, S., Teoh, O. H., Teng, S. S., Lee, K. P., Herremans, D., & Chen, J. M. (2021). Deep neural network-based respiratory pathology classification using cough sounds. *Sensors*, 21(16), 1–18. <https://doi.org/10.3390/s21165555>
- Bhavani, R., Muni, T. V., Tata, R. K., Narasimharao, J., Murali, K., & Kaur, H. (2022). Deep Learning Techniques for Speech Emotion Recognition. *2022 International Conference on Futuristic Technologies, INCOFT 2022*, 1–6. <https://doi.org/10.1109/INCOFT55651.2022.10094534>
- Bogert, B. P., Healy, M. J. R., & Tukey, J. W. (1963). The Quefrency Alanysis of Time Series for Echoes. In *Proceedings of the Symposium on Time Series Analysis* (pp. 209–243).
- CDC. (2023). *Causes of Tuberculosis*. <https://www.cdc.gov/tb/causes/index.html>.
- Davis, S. B., & Mermelstein, P. (1980). Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 28(4), 357–366.
- dos Santos, A. N., dos Reis, V. A., & Masiero, B. S. (2022). Speech Feature Extraction for Emotion Recognition Using Machine Learning. *Anais Do 12 Congresso Iberoamericano de Acústica, August*. <https://www.fia2022.com.br/arearestrita/apresentacoes/8807.pdf>
- Fedila, M., & Amrouche, M. B. A. (2018). *Gammatone filterbank and symbiotic combination of amplitude and phase-based spectra for robust speaker verification under noisy conditions and compression*. 16721–16739.
- Frame Theory for Signal Processing in Psychoacoustics*. (2016). November. <https://doi.org/10.48550/arXiv.1611.00966>
- Hermansky, H. (1990). Perceptual linear predictive (PLP) analysis of speech. *The Journal of the Acoustical Society of America*, 87(4), 1738–1752.
- Ijaz, A., Nabeel, M., Masood, U., Mahmood, T., Hashmi, M. S., Posokhova, I., Rizwan, A., & Imran, A. (2022). Towards using cough for respiratory disease diagnosis by leveraging Artificial Intelligence: A survey. *Informatics in Medicine Unlocked*, 29(October 2021), 100832. <https://doi.org/10.1016/j.imu.2021.100832>
- Jat, D. S., Limbo, A. S., & Singh, C. (2019). Voice activity detection-based home automation system for people with special needs. *Intelligent Speech Signal Processing*, 101–111. <https://doi.org/10.1016/B978-0-12-818130-0.00006-4>
- Jepsen, M. L., Eguia, J. L., McDermott, H. J., & Grayden, D. B. (2017). Investigating the use of a Gammatone filterbank for a cochlear implant speech coding strategy. *PLOS ONE*, 12(8), e0183332.
- Kopparapu, S. K., & Laxminarayana, M. (2010). Choice of Mel filter bank in computing MFCC of a resampled speech. *10th International Conference on Information Sciences, Signal Processing and Their Applications, ISSPA 2010, Isspa*, 121–124. <https://doi.org/10.1109/ISSPA.2010.5605491>
- Kreiman, J., & Gerratt, B. R. (2012). Perceptual interaction of the harmonic source and noise in voice. *He Journal of the Acoustical Society of America*, 131(1), 492–500. <https://doi.org/https://doi.org/10.1121/1.3665997>

- Kulkarni, T., Debnath, S., Kumar, J., & Mohapatra, R. K. (2023). DCT based robust coverless information hiding scheme with high capacity. *2023 7th International Conference on Trends in Electronics and Informatics (ICOEI)*, December, 358–364. <https://doi.org/10.1109/ICOEI56765.2023.10126072>
- Liu, J. M., You, M., Li, G. Z., Wang, Z., Xu, X., Qiu, Z., Xie, W., An, C., & Chen, S. (2013). Cough signal recognition with gammatone cepstral coefficients. *2013 IEEE China Summit and International Conference on Signal and Information Processing, ChinaSIP 2013 - Proceedings*, 160–164. <https://doi.org/10.1109/ChinaSIP.2013.6625319>
- Luies, L., & Preez, I. du. (2020). The echo of pulmonary tuberculosis: Mechanisms of clinical symptoms and other disease-induced systemic complications. In *Clinical Microbiology Reviews* (Vol. 33, Issue 4, pp. 1–19). American Society for Microbiology. <https://doi.org/10.1128/CMR.00036-20>
- Mann, J., Goh, N. S. L., Holland, A. E., Khor, Y. H., & Mann, J. (2021). *Cough in Idiopathic Pulmonary Fibrosis*. 2(October), 1–12. <https://doi.org/10.3389/fresc.2021.751798>
- Moore, B. C. J., & Glasberg, B. R. (1983). Suggested formulae for calculating auditory-filter bandwidths and excitation patterns. *The Journal of the Acoustical Society of America*, 74(3), 750–753.
- O'Shaughnessy, D. (2000). *Speech Communications: Human and Machine* (R. Herrick (Ed.)). IEEE Press.
- Pahar, M., Kloppe, M., Reeve, B., Warren, R., Theron, G., & Niesler, T. (2021). Automatic cough classification for tuberculosis screening in a real-world environment. *Physiological Measurement*, 42(10). <https://doi.org/10.1088/1361-6579/ac2fb8>
- Patterson, R. D., Robinson, K., Holdsworth, J., McKeown, D., Zhang, C., & Allerhand, M. (1992). An efficient auditory filterbank based on the gammatone function. *The Journal of the Acoustical Society of America*, 92(5), 2977–2977.
- Rabiner, L. R., & Juang, B. H. (1993). *Fundamentals of Speech Recognition*. Prentice-Hall, Inc.
- Ren, Z., Chang, Y., Bartl-Pokorny, K. D., Pokorny, F. B., & Schuller, B. W. (2022). The Acoustic Dissection of Cough: Diving Into Machine Listening-based COVID-19 Analysis and Detection. *Journal of Voice*. <https://doi.org/10.1016/j.jvoice.2022.06.011>
- Rohr, L. (2015). *Evaluation of audio source separation in the context of 3D audio PAR*. 6723.
- Rolo, M., González-Blanco, B., Reyes, C. A., Rosillo, N., & López-Roa, P. (2023). Epidemiology and factors associated with Extra-pulmonary tuberculosis in a Low-prevalence area. *Journal of Clinical Tuberculosis and Other Mycobacterial Diseases*, 32(May), 10–14. <https://doi.org/10.1016/j.jctube.2023.100377>
- Serrurier, A., Neuschaefer-Rube, C., & Röhrig, R. (2022). Past and Trends in Cough Sound Acquisition, Automatic Detection and Automatic Classification: A Comparative Review. *Sensors*, 22(8), 1–30. <https://doi.org/10.3390/s22082896>
- Sharan, R. V. (2023). Speech Emotion Recognition Using Gammatone Cepstral Coefficients and Deep Learning Features. *Proceedings of the 2023 IEEE International Conference on Machine Learning and Applied Network Technologies, ICMLANT 2023*, 1–4. <https://doi.org/10.1109/ICMLANT59547.2023.10372986>
- Sreeram, A. S. K., Ravishankar, U., Sripada, N. R., & Mamidgi, B. (2020). Investigating the potential of MFCC features in classifying respiratory diseases. *2020 7th International Conference on Internet of Things: Systems, Management and Security, IOTSMS 2020*. <https://doi.org/10.1109/IOTSMS52051.2020.9340166>
- Suda, C. (2023). *Early Detection of Tuberculosis with Machine Learning Cough Audio Analysis: Towards More Accessible Global Triaging Usage*. abs/2310.1, 1–15.
- WHO. (2024). *Global Tuberculosis Report 2024*.
- Yaacob, S., & Yusuf, R. (2013). *Analysis of Accent-Sensitive Words in Multi-Resolution Mel-*

- Frequency Cepstral Coefficients for Classification of Accents in Malaysian English. June.*
<https://doi.org/10.15282/ijame.7.2012.21.0086>
- Young, S., Kershaw, D., Woodland, P., Htk, T., & Version, H. T. K. (2002). *No Title. July 2000.*
- Zhao, X., & Wang, D. (2013). Analyzing noise robustness of MFCC and GFCC features in speaker identification. *ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings*, 7204–7208.
<https://doi.org/10.1109/ICASSP.2013.6639061>

(Halaman ini sengaja dikosongkan)

LAMPIRAN


Lampiran 1. Label Dataset Primer







barcode	label	sex	ground_truth
16-10-2025_1210_77	neg	m	neg
16-10-2025_1210_78	neg	m	neg
16-10-2025_1219_79	neg	f	neg
16-10-2025_1232_80	neg	f	neg
16-10-2025_1233_81	neg	f	neg
16-10-2025_1243_86	neg	m	neg
16-10-2025_1243_87	neg	m	neg
16-10-2025_1245_88	neg	f	neg
16-10-2025_1246_89	neg	f	neg
16-10-2025_1017_76	pos	f	pos
16-10-2025_1017_75	pos	f	pos
16-10-2025_0927_74	pos	f	pos
16-10-2025_0927_73	pos	f	pos
16-10-2025_0926_72	pos	f	pos
16-10-2025_0837_68	pos	m	pos
16-10-2025_0837_67	pos	m	pos
16-10-2025_0836_66	pos	m	pos
03-10-2025_0328_20	pos	m	pos
03-10-2025_0320_19	pos	m	pos
03-10-2025_0254_18	pos	m	pos
03-10-2025_0235_17	pos	f	pos

Lampiran 2. Label Dataset Sekunder (25 Data Pertama)


sex	barcode	age	ground_truth_tb	facility_code
m	01-399-0258	31	neg	Kan
m	01-399-1081	58	neg	Kan
m	02-399-0856	24	neg	Cha
f	03-399-0290	25	neg	Chai
m	01-399-0744	30	neg	Kan
f	02-399-0585	33	neg	Cha
f	03-399-0180	22	neg	Chai
m	03-399-0284	24	neg	Chai
f	02-399-0260	24	neg	Cha
m	02-399-0571	19	neg	Cha
f	01-399-0898	29	neg	Kan
m	01-399-0344	36	neg	Kan
f	02-399-0381	26	neg	Cha
m	01-399-0409	64	neg	Kan
f	01-399-0503	61	neg	Kan
m	01-399-0439	20	neg	Kan
f	02-399-0712	41	neg	Cha
m	02-399-0818	27	neg	Cha
m	02-399-0390	30	neg	Cha
f	01-399-0546	19	neg	Kan
f	02-399-0762	38	neg	Cha
m	01-399-0959	30	neg	Kan
f	01-399-0265	57	neg	Kan
f	01-399-0500	32	neg	Kan







Lampiran 3. Visualisasi Hasil Varian MFCC Sekunder





Lampiran 4. Visualisasi Hasil Varian GFCC Sekunder





BIODATA PENULIS



Penulis dilahirkan di Denpasar, 11 November 2003, merupakan anak kedua dari 2 bersaudara. Penulis telah menempuh pendidikan formal yaitu di TK Aisyiyah Bustanul Athfal 5 Denpasar, SDN 22 Dauh Puri, SMP Al Banna Denpasar dan MBI Amanatul Ummah. Setelah lulus dari MBI Amanatul Ummah, Penulis melanjutkan Pendidikan di Program Studi Teknologi Kedokteran FKK - ITS pada tahun 2022 dan terdaftar dengan NRP 5049221016.

Penulis sempat aktif di organisasi JMMI ITS, Kesatria Sepuluh Nopember, Ramadan di Kampus (RDK) ITS 46, IEEE ITS SB, Paguyuban Beasiswa Karya Salemba Empat (KSE) ITS dan Himpunan Mahasiswa Teknologi Kedokteran dan Tim Riset

Diagnostic dan Prognostic ITS.

Penulis berharap penelitian ini dapat memberikan dampak positif baik di lingkup akademik maupun masyarakat. Penulis menyadari bahwa penelitian ini masih jauh dari kata sempurna. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan untuk pengembangan lebih lanjut. Apabila pembaca ingin berdiskusi lebih lanjut dapat menghubungi penulis melalui email berikut nathaniacahyaa@gmail.com